

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ ĐÔNG Á
KHOA CÔNG NGHỆ THÔNG TIN



BÀI TẬP LỚN

HỌC PHẦN: **CHUYÊN ĐỀ TỐT NGHIỆP 3**

MÃ ĐỀ THI: **20**

TÊN ĐỀ TÀI: **PHÂN TÍCH DỮ LIỆU DU LỊCH**

LỚP TÍN CHỈ: **CĐTN3.03.K13.03.LH.C04.1_LT**

Giảng viên hướng dẫn: Lưu Thị Thảo

Danh sách sinh viên thực hiện: **Nhóm: 22**

TT	Mã sinh viên	Sinh viên thực hiện	Lớp hành chính
1	20222334	Vũ Văn Tiến	DCCNTT13.10.12

Bắc Ninh - 2026

MỤC LỤC

CHƯƠNG I: TỔNG QUAN VỀ ĐỀ TÀI.....	1
1.1 Giới thiệu đề tài	1
1.1.1 Lý do chọn đề tài.....	1
1.1.2 Mục tiêu đề tài	1
1.1.3 Đối tượng nghiên cứu	2
1.1.4 Phạm vi nghiên cứu.....	2
1.1.5 Phương pháp thực hiện	2
1.2 Công cụ và môi trường thực hiện	3
CHƯƠNG II: CƠ SỞ LÝ THUYẾT	4
2.1 Tổng quan về xử lý và phân tích dữ liệu	4
2.2 Các bước tiền xử lý dữ liệu.....	5
2.3 Cơ sở lý thuyết về thư viện sử dụng.....	6
2.3.1 NumPy	6
2.3.2 Pandas	6
2.3.3 Matplotlib (plt).....	6
2.3.4 Scikit-learn	7
2.3.5 Seaborn.....	7
2.3.6 Xgboost.....	7
2.4 Các chỉ số và phương pháp phân tích sử dụng.....	7
2.4.1 Các chỉ số đánh giá mô hình	7
2.4.2 Các phương pháp phân tích	8
2.5 Quy trình đề xuất cho bài toán	8
CHƯƠNG III: THỰC NGHIỆM.....	10
3.1 Mô tả bài toán và dữ liệu thực nghiệm	10
3.1.1 Mô tả bài toán.....	10
3.1.2 Nguồn dữ liệu và Kích thước.....	12
3.1.3 Từ điển dữ liệu.....	13
3.2 Phân tích và khảo sát dữ liệu ban đầu	16
3.2.1 Quy mô tập dữ liệu.....	16
3.2.2 Đánh giá tính toàn vẹn của dữ liệu (Missing Values)	16

3.2.3 <i>Đánh giá về Định dạng và Kiểu dữ liệu (Data Types)</i>	17
3.3 <i>Tiền xử lý dữ liệu</i>	18
3.4 <i>Trực quan hóa dữ liệu</i>	25
3.4.1 <i>Biểu đồ tổng quan</i>	25
3.4.2 <i>Biểu đồ phân phối theo chi phí</i>	27
3.4.3 <i>Biểu đồ phân phối theo độ tuổi</i>	33
3.4.4 <i>Biểu đồ tương quan</i>	38
3.4.5 <i>Một vài biểu đồ khác</i>	42
3.5 <i>Phân tích dữ liệu /Xây dựng mô hình</i>	45
3.5.1 <i>Chuẩn bị dữ liệu cho mô hình</i>	45
3.5.2 <i>Mô hình dự báo: Random Forest Regressor (Tuned)</i>	46
3.6 <i>Kết quả thực nghiệm và đánh giá</i>	46
3.6.1 <i>Các chỉ số đánh giá (Metrics)</i>	46
3.6.2 <i>Kết quả đạt được của mô hình</i>	47
CHƯƠNG IV: KẾT LUẬN	50
4.1 <i>Kết quả đạt được</i>	50
4.2 <i>Hạn chế của dự án</i>	50
4.3 <i>Hướng phát triển trong tương lai</i>	51
TÀI LIỆU THAM KHẢO	53

DANH SÁCH BẢNG BIỂU VÀ SƠ ĐỒ

Hình 3.1 Hàm đọc và kết hợp dữ liệu từ 3 file dataset khác sau	19
Hình 3.2 Hàm đọc dữ liệu từ file dataset sau khi kết hợp.....	20
Hình 3.3 Hàm kiểm tra các dữ liệu bị thiếu trong dataset.....	21
Hình 3.4 Hàm làm sạch các dữ liệu bị thiếu.....	23
Hình 3.5 Biểu đồ tổng quan.....	25
Hình 3.6 Biểu đồ Cấu trúc Chi phí Trung bình theo Độ dài Chuyến đi	27
Hình 3.7 Biểu đồ Phân phối Chi phí Hành trình & Chi phí Mỗi ngày	30
Hình 3.8 Biểu đồ Chi phí với Đường Trung bình động (Rolling Means)	31
Hình 3.9 Biểu đồ Cơ cấu Độ tuổi và Giới tính.....	34
Hình 3.10 Biểu đồ Mức độ chịu chi theo Độ tuổi	36
Hình 3.11 Biểu đồ Ma Trận Tương Quan Đa Chiều	38
Hình 3.12 Bản đồ Nhiệt (Heatmap) - Ma trận Tương quan các đặc trưng số...	40
Hình 3.13 Biểu đồ Mức độ chịu chi theo Độ tuổi	42
Hình 3.14 Biểu đồ Mức độ chịu chi theo năm tháng và mùa vụ.....	44
Bảng 1. Mô tả các cột dữ liệu có trong dataset.....	16
Bảng 2. Thống kê Missing values.....	21
Bảng 3. Thống kê chi tiết số lượng dữ liệu bị thiếu ở từng cột.....	22
Bảng 4. Mô tả về các features trong dự án.....	24
Bảng 5. Bảng phân tích chi phí trung bình theo độ dài chuyến đi	29
Bảng 6. Bảng phân tích chi phí hành trình & chi phí mỗi ngày	30
Bảng 7. Bảng phân tích chi phí với đường trung bình động (Rolling Means)..	32
Bảng 8. Bảng phân tích cơ cấu độ tuổi và giới tính.....	35
Bảng 9. Thống kê mức chi tiêu mỗi ngày (Cost per Day) theo nhóm tuổi du khách.....	37
Bảng 10. Bảng phân tích ma trận tương quan các đặc trưng số	42
Bảng 11. Bảng phân tích mức độ chịu chi theo độ tuổi.....	43
Bảng 12. Các features dành cho mô hình.....	46
Bảng 13. Bảng mô tả độ quan trọng và tỷ lệ ảnh hưởng của các features	46
Bảng 14. Bảng mô tả các chỉ số đánh giá.....	47

Bảng 15. So sánh hiệu suất giữa các mô hình thử nghiệm trên tập Test	48
Bảng 16. Bảng kết quả đạt được của mô hình.....	48

PHÂN CHIA CÔNG VIỆC

Họ và tên	Công việc
Vũ Văn Tiến	Xử lý dữ liệu đầu vào, feature engineering, trực quan hóa dữ liệu, phân tích thống kê, xây dựng mô hình học máy và hoàn thiện báo cáo.

LỜI MỞ ĐẦU

Trong bối cảnh toàn cầu hóa và sự phát triển mạnh mẽ của kỷ nguyên số, du lịch không chỉ đơn thuần là các hoạt động nghỉ dưỡng mà đã trở thành một trong những ngành công nghiệp dịch vụ mũi nhọn, đóng góp tỷ trọng khổng lồ vào nền kinh tế toàn cầu. Sự bùng nổ của các nền tảng đặt phòng trực tuyến (OTA) và các dịch vụ hàng không giá rẻ đã làm thay đổi hoàn toàn cách thức con người đi du lịch, đồng thời sinh ra một lượng dữ liệu khổng lồ về hành vi, thị hiếu và thói quen chi tiêu của hành khách.

Tuy nhiên, giữa một đại dương dữ liệu khổng lồ, việc thấu hiểu được nhu cầu thực sự của khách hàng và dự báo chính xác các biến động chi phí vẫn là một bài toán hóc búa đối với các doanh nghiệp lữ hành. Làm thế nào để biết khách hàng sẵn sàng chi trả bao nhiêu cho một chuyến đi? Yếu tố nào (độ tuổi, điểm đến hay loại hình lưu trú) thực sự quyết định độ "đắt đỏ" của một kỳ nghỉ? Nhằm đi tìm câu trả lời khách quan cho những bài toán trên thông qua lăng kính khoa học, dự án "Phân tích dữ liệu du lịch" đã được thực hiện.

Mục tiêu cốt lõi của đồ án không chỉ dừng lại ở việc làm sạch và trực quan hóa dữ liệu (EDA) để rút ra những sự thật ngầm hiểu (Insights) về thị trường, mà còn tiến xa hơn trong việc xây dựng một luồng ống (Pipeline) tự động hóa. Tại đây, thuật toán Học máy Rừng ngẫu nhiên (Random Forest Regressor) được áp dụng để mô hình hóa và dự báo chi phí lưu trú, mở ra tiềm năng ứng dụng thực tiễn trong việc gợi ý ngân sách cá nhân hóa cho từng khách hàng.

Nội dung của báo cáo được cấu trúc đi từ tổng quan đến chuyên sâu, bao gồm các phần chính: Tiền xử lý dữ liệu, Khám phá dữ liệu qua hệ thống bảng điều khiển (Dashboard), Xây dựng mô hình học máy và Đánh giá kết quả.

Dù đã dành nhiều tâm huyết và nỗ lực để hoàn thiện luồng xử lý và tối ưu hóa các dòng mã, song do giới hạn về quy mô tập dữ liệu cũng như kiến thức thực tiễn, dự án chắc chắn không tránh khỏi những thiếu sót nhất định. Rất mong nhận được sự góp ý và chỉ bảo quý báu từ các Thầy/Cô để đề tài có thể hoàn thiện hơn và tiếp tục phát triển trong tương lai.

Em xin chân thành cảm ơn!

CHƯƠNG I: TỔNG QUAN VỀ ĐỀ TÀI

1.1 Giới thiệu đề tài

Trong thời đại chuyển đổi số hiện nay, dữ liệu đóng vai trò vô cùng quan trọng trong mọi lĩnh vực, đặc biệt là ngành du lịch. Việc khai thác và phân tích dữ liệu giúp các doanh nghiệp và cơ quan quản lý hiểu rõ hơn về hành vi khách du lịch, xu hướng thị trường và hiệu quả hoạt động kinh doanh.

Đề tài “Phân tích dữ liệu du lịch” tập trung vào việc sử dụng các kỹ thuật phân tích dữ liệu và học máy để xử lý, khám phá và đưa ra các insight có giá trị từ dữ liệu du lịch, từ đó hỗ trợ việc ra quyết định và dự báo xu hướng trong tương lai.

1.1.1 Lý do chọn đề tài

Ngành du lịch là một trong những ngành kinh tế quan trọng, có tốc độ tăng trưởng nhanh và chịu ảnh hưởng mạnh mẽ từ nhiều yếu tố như kinh tế, xã hội, công nghệ. Với sự phát triển của công nghệ thông tin, lượng dữ liệu du lịch ngày càng lớn, bao gồm dữ liệu về khách hàng, địa điểm, chi tiêu, thời gian lưu trú, đánh giá dịch vụ,...

Tuy nhiên, nếu không có phương pháp xử lý và phân tích phù hợp, dữ liệu này sẽ không mang lại giá trị thực tiễn. Do đó, việc áp dụng các công cụ như NumPy, Pandas, Matplotlib và Scikit-learn để phân tích dữ liệu là cần thiết.

- Chính vì vậy, đề tài này được lựa chọn nhằm:

- + Khai thác giá trị từ dữ liệu du lịch.
- + Nâng cao kỹ năng phân tích dữ liệu.
- + Ứng dụng machine learning vào bài toán thực tế.

1.1.2 Mục tiêu đề tài

- Đề tài hướng đến các mục tiêu chính sau:

- + Thu thập và tiền xử lý dữ liệu du lịch.
- + Phân tích dữ liệu khám phá (EDA) để tìm ra các xu hướng và đặc điểm quan trọng.
- + Trực quan hóa dữ liệu giúp dễ dàng hiểu và trình bày kết quả.
- + Xây dựng mô hình dự đoán (ví dụ: dự đoán lượng khách du lịch, doanh thu, xu hướng).

Đánh giá hiệu quả mô hình bằng các chỉ số như MAE, RMSE.

Đưa ra các insight phục vụ cho việc ra quyết định.

1.1.3 Đối tượng nghiên cứu

- Đối tượng nghiên cứu của đề tài bao gồm:
- + Dữ liệu về khách du lịch (số lượng, quốc tịch, độ tuổi, hành vi).
- + Dữ liệu về địa điểm du lịch.
- + Dữ liệu doanh thu du lịch.
- + Dữ liệu thời gian (theo tháng, năm, mùa du lịch).
- + Dữ liệu đánh giá dịch vụ (nếu có).

1.1.4 Phạm vi nghiên cứu

- Phạm vi của đề tài được giới hạn như sau:
- + Tập trung vào dữ liệu du lịch trong một khu vực hoặc quốc gia cụ thể.
- + Thời gian phân tích có thể trong khoảng vài năm gần đây.
- + Không đi sâu vào các yếu tố phi dữ liệu như chính trị, văn hóa.
- + Chủ yếu tập trung vào phân tích dữ liệu và mô hình dự đoán cơ bản.

1.1.5 Phương pháp thực hiện

- Đề tài sử dụng các phương pháp và quy trình sau:
- 1. Thu thập dữ liệu: Sử dụng các dataset có sẵn từ internet hoặc nguồn mở.
- 2. Tiền xử lý dữ liệu:
 - Làm sạch dữ liệu (xử lý missing values, dữ liệu trùng lặp).
 - Chuẩn hóa dữ liệu.
 - Sử dụng thư viện NumPy và Pandas.
- 3. Phân tích dữ liệu khám phá (EDA):
 - Thống kê mô tả.
 - Tìm mối quan hệ giữa các biến.
- 4. Trực quan hóa dữ liệu:
 - Sử dụng Matplotlib (plt) để vẽ biểu đồ.
 - Biểu đồ cột, đường, histogram,...
- 5. Xây dựng mô hình dự đoán:
 - Sử dụng Scikit-learn.
 - Các mô hình như Linear Regression, Random Forest,...

6. Đánh giá mô hình: Sử dụng các chỉ số như MAE, RMSE.

1.2 Công cụ và môi trường thực hiện

- Đề tài sử dụng các công cụ và môi trường sau:

+ Ngôn ngữ lập trình: Python.

+ Thư viện sử dụng:

- NumPy: xử lý dữ liệu số
- Pandas: xử lý và phân tích dữ liệu
- Matplotlib (plt): trực quan hóa dữ liệu
- Scikit-learn: xây dựng mô hình machine learning

+ Môi trường phát triển:

- Jupyter Notebook.
- Visual Studio Code.

+ Hệ điều hành: Windows hoặc Linux.

CHƯƠNG II: CƠ SỞ LÝ THUYẾT

2.1 Tổng quan về xử lý và phân tích dữ liệu

Xử lý và phân tích dữ liệu (Data Processing and Data Analysis) là một quá trình bao gồm nhiều bước liên tiếp nhằm biến đổi dữ liệu thô (raw data) thành thông tin có ý nghĩa, từ đó hỗ trợ cho việc ra quyết định trong thực tiễn. Trong bối cảnh hiện nay, khi dữ liệu ngày càng gia tăng về khối lượng, tốc độ và đa dạng (Big Data), việc phân tích dữ liệu không chỉ dừng lại ở việc mô tả mà còn hướng đến dự đoán và tối ưu hóa.

- Trong lĩnh vực du lịch, dữ liệu có thể được thu thập từ nhiều nguồn khác nhau như:

- Hệ thống đặt phòng khách sạn.
- Ứng dụng đặt vé máy bay.
- Dữ liệu từ mạng xã hội.
- Website du lịch và đánh giá người dùng.
- Dữ liệu từ cơ quan thống kê.

- Những dữ liệu này thường có đặc điểm:

- Dữ liệu lớn (large-scale).
- Dữ liệu không đồng nhất (structured & unstructured).
- Có thể chứa nhiều nhiễu và thiếu sót.

- Do đó, việc xử lý và phân tích dữ liệu đóng vai trò cực kỳ quan trọng trong việc khai thác giá trị từ dữ liệu.

- Phân tích dữ liệu giúp các doanh nghiệp và tổ chức trong ngành du lịch:

- Hiểu hành vi khách du lịch: Phân tích dữ liệu giúp xác định khách hàng đến từ đâu, họ quan tâm đến loại hình du lịch nào, thời gian lưu trú bao lâu và mức chi tiêu ra sao.
- Xác định xu hướng du lịch theo thời gian: Thông qua dữ liệu lịch sử, có thể nhận biết các mùa cao điểm, thấp điểm, hoặc các xu hướng mới như du lịch sinh thái, du lịch trải nghiệm.
- Dự đoán nhu cầu và doanh thu: Áp dụng các mô hình học máy giúp dự báo lượng khách trong tương lai, từ đó hỗ trợ lập kế hoạch kinh doanh và phân bổ nguồn lực hợp lý.

- Tối ưu hóa chiến lược kinh doanh: Dữ liệu giúp doanh nghiệp đưa ra các quyết định chính xác hơn về giá cả, marketing, lựa chọn địa điểm và phát triển dịch vụ.

2.2 Các bước tiền xử lý dữ liệu

1. Thu thập dữ liệu (Data Collection)

- Đây là bước đầu tiên và quan trọng nhất trong toàn bộ quy trình. Dữ liệu có thể được thu thập từ: File CSV, Excel, ...
- Chất lượng dữ liệu ở bước này ảnh hưởng trực tiếp đến toàn bộ kết quả phân tích.

2. Làm sạch dữ liệu (Data Cleaning)

- Dữ liệu thô thường chứa nhiều lỗi như:

- Giá trị bị thiếu (missing values).
- Dữ liệu trùng lặp.
- Sai định dạng.
- Nhiễu (noise).

- Các kỹ thuật làm sạch bao gồm:

- Xóa hoặc thay thế dữ liệu thiếu.
- Chuẩn hóa định dạng (ngày tháng, số liệu,...).
- Loại bỏ dữ liệu bất thường.

→ Đây là bước quan trọng để đảm bảo tính chính xác của phân tích.

3. Phân tích dữ liệu khám phá (Exploratory Data Analysis - EDA)

- EDA giúp hiểu rõ cấu trúc và đặc điểm của dữ liệu thông qua:

- Thống kê mô tả (mean, median, std,...).
- Kiểm tra phân phối dữ liệu.
- Tìm mối quan hệ giữa các biến.

- Các kỹ thuật thường dùng:

- Vẽ biểu đồ (histogram, scatter, bar chart,...).
- Phân tích tương quan (correlation).
- EDA giúp phát hiện các insight ban đầu và định hướng cho bước xây dựng mô hình.

4. Xây dựng mô hình (Model Building)

- Sau khi hiểu dữ liệu, bước tiếp theo là xây dựng mô hình đề:

- Dự đoán (Regression).
- Phân loại (Classification).
- Phân cụm (Clustering).

- Một số thuật toán phổ biến:

- Linear Regression.
- Random Forest.
- Decision Tree.

→ Mô hình được huấn luyện trên tập dữ liệu train và kiểm tra trên tập test.

5. Đánh giá và đưa ra kết luận (Evaluation & Conclusion)

- Sau khi xây dựng mô hình, cần đánh giá hiệu quả bằng các chỉ số như:

- MAE (Mean Absolute Error).
- RMSE (Root Mean Squared Error).
- R^2 Score.

→ Dựa trên kết quả đánh giá, có thể:

- Điều chỉnh mô hình.
- So sánh các mô hình khác nhau.
- Đưa ra kết luận và insight.

2.3 Cơ sở lý thuyết về thư viện sử dụng

2.3.1 NumPy

Thư viện tính toán số học (numerical computing). Cung cấp mảng N chiều (ndarray) tối ưu hoá bằng C, các phép toán vector hoá, hàm thống kê (sqrt, polyfit, linspace, nan...) và đại số tuyến tính.

2.3.2 Pandas

Thư viện thao tác dữ liệu dạng bảng (tabular). Cung cấp cấu trúc DataFrame và Series — tương đương bảng SQL/Excel trong Python. Hỗ trợ đọc/ghi CSV, merge, groupby, xử lý NaN, và biến đổi dữ liệu kiểu chuỗi/thời gian.- Ứng dụng:

2.3.3 Matplotlib (plt)

Thư viện vẽ biểu đồ cơ sở (low-level plotting). Xây dựng trên mô hình Figure → Axes → Artist, cho phép kiểm soát hoàn toàn từng pixel: subplots, trục kép (twinx), color bar, lưu ảnh PNG độ phân giải cao (300 DPI).

2.3.4 Scikit-learn

Thư viện học máy (machine learning) mã nguồn mở phổ biến nhất trong hệ sinh thái Python, được xây dựng trên nền tảng NumPy và SciPy. Thư viện cung cấp một giao diện thống nhất và nhất quán cho hàng loạt thuật toán học có giám sát (supervised learning) lẫn không giám sát (unsupervised learning), bao gồm Linear Regression, Decision Tree, Random Forest, K-Nearest Neighbors và nhiều thuật toán khác. Ngoài các mô hình học máy, Scikit-learn còn hỗ trợ toàn bộ quy trình xây dựng mô hình thông qua các công cụ chia dữ liệu train/test (`train_test_split`), đánh giá chéo (`cross_val_score`), tinh chỉnh siêu tham số (`GridSearchCV`), tiền xử lý dữ liệu (`OneHotEncoder`, `ColumnTransformer`) và đóng gói pipeline (`Pipeline`). Trong dự án này, Scikit-learn được ứng dụng để xây dựng và so sánh nhiều mô hình hồi quy nhằm dự đoán chi phí lưu trú của các chuyến du lịch, đồng thời đánh giá chất lượng mô hình thông qua các chỉ số MAE, RMSE và R^2 .

2.3.5 Seaborn

Thư viện trực quan hoá thống kê (statistical visualization) xây dựng trên matplotlib. Cung cấp giao diện cấp cao cho các biểu đồ phân phối (histplot, boxplot), quan hệ (regplot, heatmap), và phân loại (barplot, countplot) kèm theme đẹp.

2.3.6 Xgboost

Thuật toán Extreme Gradient Boosting — cải tiến của Gradient Boosting với: cây quyết định tăng dần (Boosted Trees), chính quy hoá L1/L2, xử lý NaN tự động, song song hoá theo cột. Hiệu suất cao, thường đạt kết quả tốt nhất trên dữ liệu dạng bảng.

2.4 Các chỉ số và phương pháp phân tích sử dụng.

2.4.1 Các chỉ số đánh giá mô hình

1. MAE (Mean Absolute Error)

- Đo độ sai lệch trung bình tuyệt đối giữa giá trị dự đoán và thực tế

- Công thức:

$$MAE = (1/n) * \sum |y_{true} - y_{pred}|$$

2. RMSE (Root Mean Squared Error)

- Đo sai số bình phương trung bình.
- Nhạy với outliers hơn MAE.

3. R² Score (Hệ số xác định)

- Đánh giá mức độ phù hợp của mô hình
- Giá trị càng gần 1 thì mô hình càng tốt

2.4.2 Các phương pháp phân tích

1. Phân tích mô tả (Descriptive Analysis)

- Thống kê trung bình, min, max
- Hiểu tổng quan dữ liệu

2. Phân tích khám phá (EDA)

- Tìm mối quan hệ giữa các biến
- Sử dụng biểu đồ để trực quan

3. Phân tích dự đoán (Predictive Analysis)

- Sử dụng mô hình machine learning
- Dự đoán xu hướng trong tương lai

2.5 Quy trình đề xuất cho bài toán

- Quy trình thực hiện bài toán “Phân tích dữ liệu du lịch” được đề xuất như sau:

Bước 1: Thu thập dữ liệu

- Lấy dữ liệu từ file CSV hoặc nguồn mở

Bước 2: Tiền xử lý dữ liệu

- Làm sạch dữ liệu
- Xử lý missing values, outliers

Bước 3: Phân tích dữ liệu khám phá (EDA)

- Thống kê dữ liệu
- Trực quan hóa

Bước 4: Xây dựng mô hình

- Chia dữ liệu train/test
- Áp dụng thuật toán (Linear Regression, Random Forest,...)

Bước 5: Đánh giá mô hình

- Sử dụng MAE, RMSE

Bước 6: Kết luận và đề xuất

- Đưa ra insight
- Đề xuất hướng phát triển

CHƯƠNG III: THỰC NGHIỆM

3.1 Mô tả bài toán và dữ liệu thực nghiệm

3.1.1 Mô tả bài toán

Để giải quyết bài toán phân tích và dự báo chi phí du lịch, hệ thống được thiết kế theo một luồng xử lý dữ liệu (Data Pipeline) hoàn chỉnh, đi từ dữ liệu thô (raw data) đến mô hình học máy. Quy trình xử lý bao gồm 6 giai đoạn chính:

- *Giai đoạn 1: Tích hợp dữ liệu đa nguồn (Data Merging)*

Hệ thống thu thập và hợp nhất dữ liệu từ ba bộ dữ liệu độc lập về cùng một schema chuẩn thống nhất. Dataset 1 là tập dữ liệu chi tiết hành trình du lịch gốc (139 dòng), chứa thông tin về hành khách, điểm đến, chi phí lưu trú và di chuyển. Dataset 2 là bộ dữ liệu ArgoDatathon 2019 (hàng chục nghìn dòng), được tổng hợp bằng cách JOIN ba bảng flights, hotels và users theo mã hành trình và mã hành khách. Dataset 3 là tập dữ liệu du lịch Hy Lạp (3.000 dòng), trong đó tổng chi phí được ước tính phân bổ 60% cho lưu trú và 40% cho di chuyển. Sau khi chuẩn hóa về cùng cấu trúc cột, ba tập dữ liệu được nối theo chiều dọc (vertical concat) và loại bỏ các dòng trùng lặp hoàn toàn. Kết quả được lưu vào file merged_travel_data.csv.

- *Giai đoạn 2: Kiểm định dữ liệu (Data Profiling)*

Hệ thống quét toàn bộ tập dữ liệu đã hợp nhất để đánh giá tình trạng khuyết thiếu (Missing Value) trước khi can thiệp. Kết quả thống kê số lượng ô trống, tỷ lệ phần trăm thiếu của từng cột và kiểu dữ liệu được xuất tự động ra file missing_value_report.csv và trực quan hóa thành biểu đồ cột missing_values.png.

- *Giai đoạn 3: Tiền xử lý và Làm sạch (Data Cleaning)*

Giai đoạn này giải quyết các rác dữ liệu về định dạng và nội dung khuyết thiếu. Về xử lý định dạng, các cột biểu diễn tiền tệ (Accommodation cost, Transportation cost) chứa ký hiệu \$, USD và dấu phẩy được bóc tách và ép kiểu về số thực (float); các cột thời gian được chuẩn hóa về định dạng datetime. Về điền khuyết (Imputation), hệ thống áp dụng chiến lược tự động: các thuộc tính dạng số được lấp đầy bằng giá trị trung vị (Median) để tránh bị ảnh hưởng bởi nhiễu (outliers), trong khi các thuộc tính dạng chuỗi (Categorical) được điền bằng giá trị xuất hiện nhiều nhất (Mode) hoặc gán nhãn "Unknown".

- Giai đoạn 4: Trích xuất đặc trưng và Phân tích quan hệ (Feature Engineering)

Từ các thuộc tính cơ bản đã sạch, hệ thống tổng hợp thêm các đặc trưng mới để nâng cao khả năng phân tích. Cụ thể, biến Total Cost (tổng chi phí) được tạo bằng cách cộng dồn chi phí lưu trú và di chuyển; Cost per day (chi phí mỗi ngày) được tính từ tổng chi phí chia cho số ngày. Thông tin thời gian được trích xuất thành Travel Month, Travel Year, Travel Quarter và Travel Season để phân tích tính mùa vụ. Cột độ tuổi được rời rạc hóa (Binning) thành biến phân loại Age Group (Trẻ em, Thanh niên, Người trưởng thành, Trung niên, Cao niên), và độ dài chuyến đi được phân nhóm thành Duration Group. Cột Destination được tách thành Destination City và Destination Country. Tiếp theo, hệ thống tính toán ma trận tương quan Pearson để đo mức độ tác động của các biến số học lên tổng chi phí, đồng thời thống kê chi phí trung bình theo từng điểm đến, xuất ra top_correlations.csv và destination_cost_stats.csv.

- Giai đoạn 5: Phân tích khám phá và Trực quan hóa (EDA — Exploratory Data Analysis)

Dữ liệu sạch được đưa vào module trực quan hóa để tìm kiếm insight. Hệ thống tự động sinh ra 10 biểu đồ chuyên sâu dưới dạng ảnh PNG độ phân giải 300 DPI, bao gồm: Dashboard tổng quan doanh nghiệp (Executive Dashboard), biểu đồ phân phối chi phí, biểu đồ xu hướng thời gian với đường trung bình động (Rolling Mean), phân tích điểm đến (Top quốc gia phổ biến và đắt đỏ nhất), nhân khẩu học hành khách (Cơ cấu tuổi và giới tính), phân bố chi tiêu theo độ tuổi (Boxplot + Stripplot), phân tích mùa vụ (Pie Chart), cấu trúc chi phí (Stacked Bar), ma trận phân tán đa chiều kèm đường xu hướng tuyến tính (Scatter + Regplot), và Heatmap ma trận tương quan.

- Giai đoạn 6: Xây dựng và Đánh giá mô hình (Modeling & Evaluation)

Dữ liệu được chia thành tập huấn luyện (80%) và tập kiểm thử (20%) theo phương pháp Hold-out. Các biến phân loại được mã hóa bằng OneHotEncoder và đóng gói cùng mô hình trong Pipeline. Hệ thống tiến hành so sánh đồng thời bốn mô hình ứng viên — Linear Regression, Random Forest, Gradient Boosting và XGBoost — thông qua đánh giá chéo 5-fold (5-Fold Cross-Validation) trên tập train để lựa chọn mô hình tốt nhất theo chỉ số MAE. Mô hình chiến thắng sau đó được tinh chỉnh siêu tham số (Hyperparameter Tuning) bằng cách duyệt thủ công toàn bộ không gian tìm kiếm (ParameterGrid) với thanh tiến trình chi tiết. Cuối cùng, mô hình được đánh giá toàn diện trên tập kiểm thử bằng ba chỉ số tiêu chuẩn — Sai số tuyệt đối trung bình (MAE), Căn bậc hai sai số bình

phương trung bình (RMSE) và Hệ số xác định (R^2) — rồi được lưu lại (serialize) dưới định dạng .pkl cùng toàn bộ bảng so sánh hiệu suất các mô hình dưới định dạng .csv để phục vụ tái sử dụng.

3.1.2 Nguồn dữ liệu và Kích thước

Hệ thống mới thực hiện gộp (merge) theo chiều dọc 3 tập dữ liệu thô từ các nguồn thực nghiệm và thực tế khác nhau để tăng cường tính tổng quát và độ chính xác cho mô hình dự báo.

- Kích thước tập dữ liệu:

1. Dataset 1: Travel Details Dataset.

+ Kích thước: 139 dòng.

+ Đặc điểm: Chứa thông tin chi tiết đầy đủ về các chuyến đi cá nhân của du khách bao gồm chi tiết chi phí lưu trú, di chuyển và quốc tịch.

+ Link nguồn: [Traveler Trip Data on Kaggle](#).

2. Dataset 2: ArgoDatathon 2019 (Flight & Hotel Booking Data)

+ Kích thước: ~28,641 dòng.

+ Đặc điểm: Dữ liệu đặt chỗ thực tế quy mô lớn của các doanh nghiệp, được tích hợp thông qua phép JOIN giữa 3 bảng:

- flights.csv: Thông tin chuyến bay, chặng đi/đến, hạng ghế, giá vé.
- hotels.csv: Thông tin khách sạn, số ngày lưu trú, tổng chi phí khách sạn.
- users.csv: Thông tin khách hàng (tuổi, giới tính, công ty).

+ Link nguồn: [ArgoDatathon 2019 on Kaggle](#).

3. Dataset 3: Greece Travel Data

+ Kích thước: 3,000 dòng.

+ Đặc điểm: Tập dữ liệu khảo sát du lịch chuyên sâu tại Hy Lạp. Đối với tập dữ liệu này, chi phí tổng cộng chuyến đi được phân bổ ước lượng theo tỷ lệ thực tế ngành du lịch: 60% chi phí lưu trú (Accommodation cost) và 40% chi phí di chuyển (Transportation cost).

+ Link nguồn: [Greece Travel Data on Kaggle](#).

- Kích thước tập dữ liệu gộp (Merged Dataset):

+ Tổng số dòng sau khi gộp & lọc trùng hoàn toàn: 31,780 dòng.

+ Tổng số thuộc tính gốc sau chuẩn hóa: 11 cột.

+ Phân bổ số lượng dòng theo nguồn dữ liệu:

- dataset_2 (ArgoDatathon 2019): 28,641 dòng (chiếm ~90.1%).

- dataset_3 (Greece Travel Data): 3,000 dòng (chiếm ~9.4%).
- dataset_1 (Travel Details Dataset): 139 dòng (chiếm ~0.5%).

3.1.3 Từ điển dữ liệu

- Dưới đây là bảng mô tả chi tiết cấu trúc Schema chung sau khi thực hiện tích hợp, chuyển đổi kiểu dữ liệu và chuẩn hoá từ 3 tập dữ liệu thô:

STT	Tên thuộc tính	Kiểu dữ liệu gốc	Kiểu dữ liệu chuẩn hóa	Mô tả ý nghĩa
1	Destination	String	String (Categorical)	Điểm đến của chuyến đi. • DS1: Tên quốc gia/thành phố. • DS2: Lấy từ trường thành phố đến (to). • DS3: Mặc định gán là 'Greece'.
2	Start date	String (Datetime)	Datetime	Ngày bắt đầu hành trình. • DS1: Ngày bắt đầu chuyến đi. • DS2: Lấy từ ngày khởi hành chuyến bay (date_flight). • DS3: Lấy từ ngày du lịch (Date of Travel).
3	Duration (days)	Numeric (Int/Float)	Float (Continuous)	Tổng số ngày lưu trú của hành trình. • DS1: Số ngày đi du lịch. • DS2: Lấy từ số ngày ở khách sạn (days). • DS3: Lấy từ thời gian đi (Duration).
4	Traveler age	Numeric (Int/Float)	Float (Continuous)	Độ tuổi của hành khách. • DS1: Tuổi của khách

				du lịch. • DS2: Lấy từ tuổi người dùng (age). • DS3: Lấy từ tuổi (Age).
5	Traveler gender	String	String (Categorical)	Giới tính của hành khách. Chuẩn hóa về các nhãn chính viết hoa chữ cái đầu: Male, Female, Non-binary hoặc Unknown.
6	Traveler nationality	String	String (Categorical)	Quốc tịch của hành khách. • DS1, DS3: Lấy trực tiếp từ dữ liệu thô. • DS2: Bị khuyết hoàn toàn, hệ thống tự động điền bằng giá trị phổ biến nhất (Mode) hoặc 'Unknown'.
7	Accommodation type	String	String (Categorical)	Hình thức / Loại hình lưu trú. • DS1: Khách sạn, Airbnb, Resort... • DS2: Tên khách sạn cụ thể từ bảng hotels. • DS3: Lấy từ trường nơi ở (Stay) được map về các nhãn chuẩn (Hotel, Airbnb, Hostel, Resort).
8	Accommodation	String/Numeric	Float (Continuous)	Chi phí lưu trú (Đơn vị:

	cost			USD). • DS1: Giá trị số sau khi làm sạch ký tự lạ (\$, USD, ,). • DS2: Tổng chi phí phòng khách sạn (total). • DS3: Ước lượng bằng 60% tổng chi phí chuyến đi.
9	Transportation type	String	String (Categorical)	Phương tiện / Loại hình di chuyển. • DS1, DS3: Chuyển bay, ô tô, tàu hỏa... • DS2: Bản đồ hóa hạng ghế bay (flightType → First Class Flight, Economy Flight, Business Flight).
10	Transportation cost	String/Numeric	Float (Continuous)	Chi phí di chuyển (Đơn vị: USD). • DS1: Giá trị số sau khi làm sạch ký tự lạ. • DS2: Tổng chi phí các chặng bay của chuyến đi (total_flight_cost). • DS3: Ước lượng bằng 40% tổng chi phí chuyến đi.
11	source	-	String (Categorical)	Nguồn dữ liệu gốc của bản ghi, dùng để kiểm soát và đánh giá mức độ ảnh hưởng của từng

				nguồn (dataset_1, dataset_2, dataset_3).
--	--	--	--	---

Bảng 1. Mô tả các cột dữ liệu có trong dataset

3.2 Phân tích và khảo sát dữ liệu ban đầu

Trước khi tiến hành tiền xử lý và xây dựng mô hình học máy, bước khảo sát dữ liệu ban đầu (Data Profiling) được thực hiện một cách nghiêm ngặt nhằm đánh giá quy mô, đặc điểm kiểu dữ liệu và chất lượng thực tế của tập dữ liệu thô sau khi được tích hợp từ các nguồn khác nhau. Qua quá trình rà quét tập dữ liệu gộp đa nguồn (merged_travel_data.csv), chúng tôi thu được các đánh giá định lượng và định tính cụ thể như sau:

3.2.1 Quy mô tập dữ liệu

Quy mô của tập dữ liệu đã được nâng cấp đáng kể để đáp ứng yêu cầu của các thuật toán học máy hiện đại:

- Tổng số mẫu (Dòng): Tập dữ liệu có quy mô lớn với tổng cộng 31,780 dòng (đại diện cho 31,780 chuyến đi và hành trình du lịch thực tế khác nhau), tăng gấp 228 lần so với phiên bản cũ (139 dòng).
- Số lượng đặc trưng (Cột): Gồm 11 cột thuộc tính gốc được tích hợp đồng bộ từ 3 tập dữ liệu thô (đã loại bỏ thuộc tính định danh không mang giá trị phân tích là Trip ID). Tập dữ liệu là sự kết hợp phức tạp giữa các nhóm biến phân loại (Categorical), biến liên tục (Numerical) và biến thời gian (Datetime).

3.2.2 Đánh giá tính toàn vẹn của dữ liệu (Missing Values)

Quá trình thống kê giá trị khuyết thiếu (NULL/NaN) cho thấy tập dữ liệu thô không hoàn chỉnh và cần được can thiệp:

- Tỷ lệ khuyết thiếu toàn cục: Có 9 trên tổng số 11 cột bị thiếu dữ liệu ở các mức độ khác nhau. Tổng số ô dữ liệu bị trống trong toàn bảng là 38,007 ô trên tổng số 349,580 ô, tương đương tỷ lệ khuyết thiếu toàn cục khoảng 10.87%. Cột duy nhất toàn vẹn 100% không khuyết thiếu là cột nguồn dữ liệu (source).
- Các cột bị khuyết dữ liệu diện rộng (Hệ thống):
 - + Traveler nationality (Quốc tịch): Khuyết 28,643 dòng (chiếm tỷ lệ cực cao 90.13%). Nguyên nhân chính là do nguồn dữ liệu lớn nhất — Dataset 2 (ArgoDatathon 2019, chiếm 90.1% tổng số dòng) hoàn toàn không thu thập thông tin quốc tịch của du khách.

+ Traveler gender (Giới tính): Khuyết 9,354 dòng (chiếm tỷ lệ 29.43%), phân bố rải rác ở cả Dataset 2 và Dataset 3.

- Các cột khuyết thiếu mức độ ngẫu nhiên cực thấp:

+ Transportation cost và Transportation type bị khuyết 2 dòng (tỷ lệ 0.01%).

+ Duration (days), Destination, Start date, Accommodation type, Traveler age, và Accommodation cost chỉ bị khuyết đúng 1 dòng duy nhất (tỷ lệ ~0.00%).

→ Nhận xét & Giải pháp: Do tính chất khuyết thiếu cực kỳ không đồng đều và tập trung ở các biến phân loại nhân khẩu học, việc áp dụng phương pháp xóa bỏ trực tiếp các dòng khuyết thiếu (Listwise Deletion) là hoàn toàn không khả thi, vì nó sẽ hủy hoại hơn 90% lượng dữ liệu quý giá của hệ thống (đặc biệt là mất đi toàn bộ Dataset 2). Do đó, chúng tôi bắt buộc phải áp dụng giải pháp Điền khuyết (Imputation) có chọn lọc:

- Đối với đặc trưng số (Numerical): Sử dụng giá trị Trung vị (Median) để điền nhằm bảo toàn phân phối của thuộc tính và loại trừ ảnh hưởng của các giá trị ngoại lai (outliers).
- Đối với đặc trưng phân loại (Categorical): Sử dụng giá trị Yếu vị (Mode) phổ biến nhất, hoặc gán nhãn giá trị khuyết thiếu thành một nhóm phân loại mới là 'Unknown' (đặc biệt ở các trường bị khuyết hệ thống diện rộng) nhằm giúp các mô hình học máy vẫn có thể học và nhận diện được đặc trưng này.

3.2.3 Đánh giá về Định dạng và Kiểu dữ liệu (Data Types)

Do quá trình tích hợp dữ liệu đa nguồn từ nhiều hệ thống lưu trữ độc lập khác nhau, hệ thống phát hiện ra rất nhiều sự không đồng nhất về định dạng và kiểu dữ liệu cần được xử lý chuẩn hóa triệt để:

1. Bất thường ở các biến chi phí (Costs):

Tại Dataset 1, hai thuộc tính Accommodation cost và Transportation cost chứa dữ liệu giá trị tiền tệ nhưng lại bị phần mềm Pandas nhận diện dưới dạng chuỗi văn bản (String/Object). Lý do là các ô dữ liệu này kẹp lẫn các ký tự đặc biệt, ký hiệu ngoại tệ hoặc dấu phân cách như ký hiệu đô la (\$), chữ viết tắt (USD), và dấu phẩy phân cách hàng nghìn (,), ví dụ: "\$1,200 USD".

Tại Dataset 3, giá trị chi phí bị khuyết và phải được phân bổ gián tiếp từ tổng chi phí chuyến đi theo tỷ lệ thực tế ngành (60% lưu trú / 40% di chuyển). Do đó, hệ thống bắt buộc phải bóc tách chuỗi ký tự, loại bỏ các ký tự phi số thông qua hàm làm sạch chuyên dụng `_clean_cost()` và ép kiểu dữ liệu đồng bộ về dạng số thực (Float) để các mô hình hồi quy có thể tính toán được.

2. Bất thường ở các biến thời gian (Datetime):

Trường thời gian khởi hành Start date và ngày kết thúc End date (đối với Dataset 2 là ngày bay date_flight, Dataset 3 là Date of Travel) đều đang bị lưu dưới dạng chuỗi ký tự thô (Object) với các chuẩn hiển thị khác nhau tùy theo nguồn (ví dụ: YYYY-MM-DD, DD/MM/YYYY hoặc MM/DD/YYYY).

Việc sai lệch kiểu dữ liệu này ngăn cản hoàn toàn khả năng tính toán độ dài hành trình thực tế hoặc trích xuất các đặc trưng thời gian hữu ích (như tháng khởi hành, năm khởi hành, quý và mùa vụ du lịch). Các cột này cần được chuyển đổi đồng bộ về định dạng chuẩn datetime64[ns] bằng phương pháp ép kiểu có kiểm soát lỗi (errors='coerce').

3. Sự không nhất quán của dữ liệu chuỗi ký tự (String Inconsistency):

Do được thu thập từ nhiều biểu mẫu khảo sát và hệ thống khác nhau, các giá trị dạng chuỗi phân loại (như Destination, Accommodation type, Transportation type, Traveler gender, Traveler nationality) tồn tại rất nhiều khoảng trắng thừa ở đầu hoặc cuối chuỗi. Nếu không được cắt tỉa (.str.strip()), các thuật toán nhóm dữ liệu (Groupby hoặc OneHotEncoder) sẽ coi các chuỗi có khoảng trắng là các phân loại hoàn toàn khác biệt (ví dụ: " Hotel" và "Hotel").

Hơn nữa, các lớp phân loại còn bị viết hoa/viết thường không đồng nhất (ví dụ: male, Male, MALE hoặc female, Female). Chúng cần được chuẩn hóa đồng bộ về định dạng viết hoa chữ cái đầu (.str.capitalize()) hoặc ánh xạ qua các từ điển cấu hình chuẩn (gender_map, transport_map, stay_map) để đồng nhất các nhóm phân loại.

3.3 Tiền xử lý dữ liệu

- Bước 1: Thu thập và thống kê dữ liệu

```

1  def merge_all_datasets() -> pd.DataFrame:
2      """
3      Gộp (concat theo chiều dọc) cả 3 tập dữ liệu thô về chung 1 schema chuẩn.
4      Kết quả được lưu vào data/processed/merged_travel_data.csv.
5
6      Trả về:
7          pd.DataFrame: DataFrame đã merge, chưa làm sạch.
8      """
9      print("=" * 55)
10     print("  BUOC 0: MERGE 3 DATASETS")
11     print("=" * 55)
12
13     df1 = _load_ds1()
14     df2 = _load_ds2()
15     df3 = _load_ds3()
16
17     merged = pd.concat([df1, df2, df3], ignore_index=True)
18
19     # Loại bỏ dòng trùng hoàn toàn
20     before = len(merged)
21     merged = merged.drop_duplicates()
22     removed = before - len(merged)
23
24     print("-" * 55)
25     print(f"  Tong so dong sau merge : {len(merged)}")
26     print(f"  Phan bo theo nguon:")
27     for src, cnt in merged['source'].value_counts().items():
28         print(f"    {src:<12}: {cnt:>6} dong")
29     if removed:
30         print(f"  Da loai bo {removed} dong trung lap.")
31
32     merged.to_csv(DATA_MERGED, index=False)
33     print(f"  File merged da luu tai: {DATA_MERGED}")
34     print("=" * 55)
35     return merged

```

Hình 3.1 Hàm đọc và kết hợp dữ liệu từ 3 file dataset khác sau

→ Nhận xét: Hàm `merge_all_datasets()` được thiết kế rất modular và mạch lạc khi tách biệt logic nạp dữ liệu thô sang các hàm con, thực hiện gộp dọc và lọc trùng lặp một cách chuẩn xác, đồng thời tích hợp cơ chế ghi nhật ký (logging) trực quan về tỷ lệ phân bổ nguồn dữ liệu và tự động lưu kết quả trung gian giúp tối ưu hóa quy trình kiểm soát chất lượng dữ liệu.

```

1 def load_data(data_path: str) -> pd.DataFrame | None:
2     """Đọc file CSV dữ liệu (dùng cho cả file gốc lẫn file đã merge)."""
3     try:
4         df = pd.read_csv(data_path)
5         # Bỏ cột Trip ID nếu có (cột ID không mang thông tin phân tích)
6         if "Trip ID" in df.columns:
7             df = df.drop(columns=["Trip ID"])
8             print(f"Đã tải dữ liệu: {df.shape[0]} dòng x {df.shape[1]} cột ({data_path})")
9             return df
10    except Exception as e:
11        print(f" [LOI] Không thể tải dữ liệu: {e}")
12        return None

```

Hình 3.2 Hàm đọc dữ liệu từ file dataset sau khi kết hợp

→ Nhận xét: Hàm `load_data()` được xây dựng an toàn và tối ưu nhờ cơ chế bọc lỗi try-except tránh gây crash hệ thống, đồng thời tích hợp sẵn bước tiền xử lý thông minh khi tự động loại bỏ cột định danh nhiễu (Trip ID) và ghi nhận tường minh kích thước tệp dữ liệu đã nạp thành công.

```

1 def missing_value_summary(df: pd.DataFrame) -> pd.DataFrame:
2     """
3     Tạo báo cáo thống kê Missing Value của từng cột TRƯỚC KHI làm sạch.
4     Kết quả lưu vào MISSING_VALUE_REPORT_PATH.
5
6     Trả về:
7     pd.DataFrame: Bảng tổng hợp missing value.
8     """
9     total_rows = len(df)
10    report = pd.DataFrame({
11        'column'      : df.columns,
12        'dtype'       : df.dtypes.values,
13        'total_count'  : total_rows,
14        'missing_count' : df.isnull().sum().values,
15        'non_missing'  : df.notnull().sum().values,
16    })
17    report['missing_percent (%)'] = (report['missing_count'] / total_rows * 100).round(2)
18    report = report.sort_values('missing_count', ascending=False).reset_index(drop=True)
19    report.to_csv(MISSING_VALUE_REPORT_PATH, index=False)
20
21    total_missing      = report['missing_count'].sum()
22    cols_with_missing  = (report['missing_count'] > 0).sum()
23    print("-" * 50)
24    print(" THONG KE MISSING VALUE (truoc khi clean)")
25    print("-" * 50)
26    print(f" Tong so dong      : {total_rows}")
27    print(f" Tong so cot       : {len(df.columns)}")
28    print(f" Cot co missing     : {cols_with_missing}/{len(df.columns)}")
29    print(f" Tong o bi thieu    : {total_missing}")
30    print(f" Bao cao da luu tai: {MISSING_VALUE_REPORT_PATH}")
31    print("-" * 50)
32    return report

```

Hình 3.3 Hàm kiểm tra các dữ liệu bị thiếu trong dataset

→ Nhận xét: Hàm *missing_value_summary()* thực hiện khảo sát chất lượng dữ liệu rất chuyên nghiệp và trực quan khi tự động tính toán chi tiết số lượng, tỷ lệ khuyết thiếu của từng thuộc tính theo thứ tự giảm dần, đồng thời tự động xuất báo cáo ra tệp CSV độc lập và ghi nhận tóm tắt nhanh lên console giúp người dùng dễ dàng định lượng mức độ phân mảnh dữ liệu.

Thống kê Missing values	
Tổng số dòng	31780
Tổng số cột	11
Cột có dữ liệu bị thiếu	10/11
Tổng ô bị thiếu	38007

Bảng 2. Thống kê Missing values

Column	Dtype	Total_Count	Missing_count	Non_missing
Traveler nationality	str	31780	28643	3137
Traveler gender	str	31780	9354	22426
Transportation cost	float64	31780	2	31778
Transportation type	str	31780	2	31778
Duration (days)	float64	31780	1	31779
Destination	str	31780	1	31779
Start date	str	31780	1	31779
Accommodation type	str	31780	1	31779
Traveler age	float64	31780	1	31779
Accommodation cost	float64	31780	1	31779
source	str	31780	0	31780

Bảng 3. Thống kê chi tiết số lượng dữ liệu bị thiếu ở từng cột

→ Nhận xét: Kết quả rà quét cho thấy bức tranh toàn cảnh về độ toàn vẹn của dữ liệu sau khi gộp nguồn, chỉ ra sự khuyết thiếu mang tính hệ thống tập trung chủ yếu ở thuộc tính Traveler nationality (90.13%) và Traveler gender (29.43%), trong khi các cột đặc trưng quyết định đến chi phí hành trình lại cực kỳ toàn vẹn (>99.99%), tạo cơ sở thực chứng vững chắc để nhóm nghiên cứu lựa chọn chiến lược điền khuyết (Imputation) thay vì xóa bỏ mẫu.

- B2: Làm sạch dữ liệu

```

1  def clean_data(df: pd.DataFrame) -> pd.DataFrame:
2      """
3      Làm sạch DataFrame:
4      - Loại bỏ dòng trống hoàn toàn.
5      - Chuẩn hóa tên cột (strip whitespace).
6      - Làm sạch cột chi phí (loại bỏ $, dấu phẩy).
7      - Chuyển đổi cột ngày sang datetime.
8      - Điền missing: cột số → Median, cột chuỗi → Mode.
9      """
10     df = df.dropna(how='all')
11     df.columns = df.columns.str.strip()
12
13     def _clean_cost(val):
14         if pd.isna(val): return np.nan
15         if isinstance(val, (int, float)): return float(val)
16         val = str(val).replace('$', '').replace(',', '').replace('USD', '').strip()
17         try:
18             return float(val)
19         except ValueError:
20             return np.nan
21
22     for col in ['Accommodation cost', 'Transportation cost']:
23         if col in df.columns:
24             df[col] = df[col].apply(_clean_cost)
25
26     for col in ['Start date', 'End date']:
27         if col in df.columns:
28             df[col] = pd.to_datetime(df[col], errors='coerce')
29
30     # Điền missing value – cột số dùng median, cột chuỗi dùng mode
31     for col in df.select_dtypes(include=[np.number]).columns:
32         df[col] = df[col].fillna(df[col].median())
33
34     for col in df.select_dtypes(include=['object']).columns:
35         mode_val = df[col].mode()
36         df[col] = df[col].fillna(mode_val[0] if not mode_val.empty else 'Unknown')
37
38     return df

```

Hình 3.4 Hàm làm sạch các dữ liệu bị thiếu

- B3: Tạo features mới

Feature	Công thức	Mô tả
Total Cost	$df['Accommodation\ cost'] + df['Transportation\ cost']$	Tổng chi phí chuyến đi (bằng Chi phí Lưu trú cộng Chi phí Di chuyển).
Cost per day	$df['Total\ Cost'] / df['Duration\ (days)']$	Tổng chi phí trung bình cho mỗi ngày của chuyến đi (mức độ tiêu

		dùng chung).
Accommodation cost per day	df['Accommodation cost'] / df['Duration (days)']	Chi phí lưu trú trung bình cho mỗi ngày (mức độ chịu chi cho nơi ở).
Travel Month	df['Start date'].dt.month	Tháng bắt đầu chuyến đi (Nhận giá trị số từ 1 đến 12).
Travel Year	df['Start date'].dt.year	Năm diễn ra chuyến đi (phục vụ phân tích xu hướng tăng trưởng qua các năm).
Travel Quarter	df['Start date'].dt.quarter	Quý khởi hành hành trình (Nhận giá trị số từ 1 đến 4).
Travel Season	df['Travel Month'].map(season_map)	Mùa khởi hành (Ánh xạ các tháng du lịch về: Mùa Xuân, Mùa Hè, Mùa Thu, Mùa Đông).
Age Group	pd.cut(df['Traveler age'], bins=[0, 18, 25, 35, 50, 65, 100], labels=labels)	Phân nhóm độ tuổi của du khách (Trẻ em, Thanh niên, Người trưởng thành, Trung niên, Trung cao niên, Cao niên).
Duration Group	pd.cut(df['Duration (days)'], bins=[0, 3, 7, 14, 9999], labels=labels)	Phân nhóm thời gian lưu trú (Ngắn ngày (<=3), Vừa (4-7), Dài ngày (8-14), Rất dài (>14)).
Destination City	df['Destination'].str.split(',', n=1, expand=True)[0]	Tên thành phố đến (Tách từ phần trước dấu phẩy của trường điểm đến gốc).
Destination Country	df['Destination'].str.split(',', n=1, expand=True)[1]	Tên quốc gia đến (Tách từ phần sau dấu phẩy; nếu không có sẽ tự điền bằng tên thành phố).

Bảng 4. Mô tả về các features trong dự án

→ Nhận xét: Quá trình Feature Engineering đã trích xuất thành công 11 đặc trưng mới, giúp làm giàu thông tin cho tập dữ liệu thô ban đầu. Cụ thể:

- Biến tỷ lệ (Cost per day): Đưa chi phí các chuyến đi dài ngắn khác nhau về cùng một hệ quy chiếu để so sánh khách quan.


- Biến thời gian (Season, Month): Giúp hệ thống phân tích được tính mùa vụ trong hành vi du lịch.

- Biến phân khúc (Age Group, Duration Group): Rời rạc hóa số liệu thành các nhóm phân loại, giúp dễ dàng vẽ biểu đồ nhân khẩu học và hỗ trợ mô hình Machine Learning nắm bắt quy luật tốt hơn.

=> Kết luận: Các đặc trưng phái sinh này đóng vai trò then chốt giúp tăng độ chính xác cho cả báo cáo EDA lẫn mô hình dự báo.

3.4 Trực quan hóa dữ liệu

3.4.1 Biểu đồ tổng quan



Hình 3.5 Biểu đồ tổng quan

1. Biến động tổng chi tiêu du lịch theo chuỗi thời gian (Biểu đồ trên - bên trái)

- Mô tả kỹ thuật: Biểu đồ diện tích (Area Chart) biểu diễn tổng chi phí du lịch tích lũy (Total Cost sum) theo dòng thời gian tuyến tính tháng-năm (YearMonth), kết hợp đường xu hướng màu xanh dương đậm và phần nền được phủ bóng mờ.

- Ý nghĩa phân tích: Biểu đồ này phản ánh trực quan sự trỗi sụt của tổng lượng cầu du lịch trên thị trường. Các đỉnh nhọn cao đại diện cho các chu kỳ bùng nổ chi tiêu (thường rơi vào mùa cao điểm du lịch hè hoặc kỳ nghỉ lễ lớn), trong khi các thung lũng sâu thể

hiện giai đoạn đóng băng hoặc thấp điểm của thị trường. Nhìn vào biểu đồ chuỗi thời gian này, các nhà quản lý có thể đánh giá được tính chu kỳ và sự tăng trưởng dài hạn của dòng tiền tiêu dùng trong ngành du lịch.

2. Biến động chi phí trung bình theo tháng và tính quy luật mùa vụ (Biểu đồ trên - bên phải)

- Mô tả kỹ thuật: Biểu đồ cột đứng (Bar Chart) thể hiện chi phí trung bình của mỗi chuyến đi (Total Cost mean) phân bổ theo 12 tháng trong năm. Trực quan hóa được nâng cấp bằng cách dán nhãn giá trị chi phí trực tiếp trên đầu mỗi cột và phân nhóm màu sắc theo các mùa vụ trong năm (Màu xanh lá cho Quý 1, Xanh dương cho Quý 2-3 và Đỏ cho Quý 4).

- Ý nghĩa phân tích: Biểu đồ cho thấy tính quy luật thời tiết và mùa vụ ảnh hưởng trực tiếp đến giá cả dịch vụ du lịch. Chi phí trung bình thường tăng vọt ở các tháng hè cao điểm (Tháng 6, 7, 8) do nhu cầu nghỉ dưỡng của gia đình tăng mạnh dẫn đến giá phòng khách sạn và vé máy bay đạt đỉnh. Ngược lại, chi phí giảm sút đáng kể vào giai đoạn chuyển mùa (Tháng 9, 10) - thời điểm lý tưởng để các công ty lữ hành kích cầu bằng các chương trình giảm giá. Việc hiển thị số liệu cụ thể giúp doanh nghiệp dễ dàng định vị các mức giá sàn và giá trần theo tháng để tối ưu hóa chiến dịch doanh thu.

3. Mối tương quan giữa Thời gian lưu trú và Tổng chi phí (Biểu đồ dưới - bên trái)

- Mô tả kỹ thuật: Biểu đồ phân tán (Scatter Plot) khảo sát mối liên hệ giữa hai biến liên tục: Thời gian lưu trú (Duration (days)) ở trục hoành và Tổng chi phí (Total Cost) ở trục tung. Mỗi điểm dữ liệu đại diện cho một chuyến đi, được tô màu theo năm (Travel Year sử dụng dải màu gradient từ tối đến sáng) và được dẫn dắt bởi một đường xu hướng tuyến tính (Trendline) màu đỏ đứt đoạn.

- Ý nghĩa phân tích: Đường hồi quy tuyến tính màu đỏ có độ dốc dương lớn khẳng định một quy luật hiển nhiên: Thời gian lưu trú càng dài thì tổng chi phí chuyến đi càng lớn. Tuy nhiên, mật độ phân tán của các điểm dữ liệu xung quanh đường trendline còn tiết lộ thêm phân khúc tiêu dùng của hành khách. Những điểm nằm lệch hẳn lên phía trên đường xu hướng đại diện cho nhóm du lịch cao cấp (chuyến đi ngắn ngày nhưng chi phí rất cao do sử dụng dịch vụ khách sạn 5 sao hoặc bay hạng thương gia). Ngược lại, các điểm nằm sát trục hoành thể hiện nhóm du lịch tiết kiệm (phượt, hostel giá rẻ). Sự dịch chuyển màu sắc của các điểm theo năm cũng phản ánh mức chi tiêu trung bình đang có xu hướng tăng dần theo thời gian.


4. Xu hướng lạm phát và phân phối chi phí du lịch theo năm (Biểu đồ dưới - bên phải)

- Mô tả kỹ thuật: Biểu đồ hộp (Boxplot) trực quan hóa phân phối của Tổng chi phí (Total Cost) qua các năm độc lập. Biểu đồ được tinh chỉnh tối giản với viền xanh dương thanh lịch, thể hiện rõ 5 chỉ số thống kê đặc trưng: Giá trị nhỏ nhất (Min), Tứ phân vị thứ nhất (\$Q_1\$), Trung vị (Median), Tứ phân vị thứ ba (\$Q_3\$), Giá trị lớn nhất (Max) và các giá trị ngoại lai (Outliers).

- Ý nghĩa phân tích: Biểu đồ hộp là công cụ đắc lực để so sánh sự thay đổi cấu trúc chi tiêu qua từng năm tài khóa. Đường trung vị (vạch nằm ngang giữa hộp) dịch chuyển tịnh tiến lên phía trên qua các năm cho thấy một xu hướng tăng trưởng chi phí liên tục. Điều này có thể giải thích bởi hai nguyên nhân chính: tác động của lạm phát kinh tế làm tăng giá dịch vụ du lịch toàn cầu, hoặc mức độ chịu chi của khách hàng ngày càng nâng cao. Khoảng cách giữa các hộp (\$Q_3 - Q_1\$) cho thấy độ phân hóa giàu nghèo trong tiêu dùng du lịch ngày càng giãn rộng qua các năm, đòi hỏi doanh nghiệp phải đa dạng hóa các gói dịch vụ từ bình dân đến cao cấp để đáp ứng thị trường.

3.4.2 Biểu đồ phân phối theo chi phí

- Biểu đồ này bóc tách tỷ trọng giữa hai loại chi phí cốt lõi: Lưu trú (Accommodation) và Di chuyển (Transportation) dựa trên thời gian đi du lịch.



Hình 3.6 Biểu đồ Cấu trúc Chi phí Trung bình theo Độ dài Chuyến đi

Nhóm thời gian lưu trú	Tổng chi phí trung bình	Chi phí Lưu trú	Chi phí Di chuyển	Nhận xét phân bổ chi phí
Ngắn ngày (<=3 ngày)	~2,516 \$	~574 \$ (22.8%)	~1,942 \$ (77.2%)	Di chuyển áp đảo: Du khách đi ngắn ngày tiêu tốn phần lớn ngân sách cho phương tiện di chuyển nhanh (vé máy bay/tàu hỏa), trong khi chi phí lưu trú chiếm tỷ trọng nhỏ do số đêm ở lại ít.
Vừa (4 - 7 ngày)	~3,522 \$	~1,387 \$ (39.4%)	~2,135 \$ (60.6%)	Di chuyển vẫn chiếm ưu thế: Chi phí lưu trú đã tăng lên đáng kể khi thời gian ở lại tăng, nhưng chi phí di chuyển vẫn là thành phần chính chiếm hơn 60% tổng chi tiêu.
Dài ngày (8 - 14 ngày)	~16,294 \$	~9,776 \$ (60.0%)	~6,518 \$ (40.0%)	Lưu trú vượt trội hoàn toàn: Tổng chi phí tăng vọt gấp hơn 4.6 lần so với nhóm vừa ngày. Lúc này, chi phí lưu trú chiếm tỷ trọng áp đảo 60%, phản ánh xu


				hướng sử dụng dịch vụ lưu trú chất lượng cao trong các chuyến đi dài ngày.
Rất dài (>14 ngày)	~17,611 \$	~10,567 \$ (60.0%)	~7,044 \$ (40.0%)	Cấu trúc chi tiêu đạt đỉnh: Tổng chi phí đạt mức cao nhất. Tỷ lệ phân bổ 60% lưu trú và 40% di chuyển được giữ vững ổn định, cho thấy đây là cấu trúc chi tiêu chuẩn mực của các chuyến đi dài hạn quy mô lớn.

Bảng 5. Bảng phân tích chi phí trung bình theo độ dài chuyến đi

Đối với các chuyến đi dưới 7 ngày (Ngắn & Vừa ngày): Chi phí di chuyển (Transportation cost) đóng vai trò là "chi phí cố định ban đầu" chiếm tỷ trọng áp đảo (lần lượt là 77.2% và 60.6%). Điều này hoàn toàn phù hợp với thực tế: dù bạn ở lại 1 ngày hay 5 ngày thì giá vé máy bay hoặc phương tiện di chuyển đường dài khứ hồi vẫn là một khoản chi lớn cố định và không thay đổi theo số đêm bạn lưu trú.

Đối với các chuyến đi trên 8 ngày (Dài & Rất dài ngày): Khi thời gian lưu trú kéo dài, chi phí phòng khách sạn tích lũy qua từng đêm bắt đầu phát huy hiệu ứng cộng dồn mạnh mẽ. Lúc này, cấu trúc chi tiêu có sự xoay trục ngoạn mục khi Chi phí Lưu trú (Accommodation cost) vượt qua chi phí di chuyển và vươn lên chiếm tỷ trọng tuyệt đối 60% trong tổng ngân sách chuyến đi. Khoản chi cho di chuyển lúc này chỉ còn chiếm 40%. Sự ổn định của tỷ lệ phân bổ 60/40 ở cả hai nhóm Dài ngày và Rất dài ngày chứng minh đây là trạng thái bão hòa tiêu chuẩn của các hành trình dài hạn.

→ Thời gian lưu trú càng dài, chi phí cố định (Di chuyển) càng được tối ưu hóa trên mỗi ngày, nhường chỗ cho sự gia tăng chất lượng trải nghiệm lưu trú.



Hình 3.7 Biểu đồ Phân phối Chi phí Hành trình & Chi phí Mỗi ngày

Hai biểu đồ này đo lường sự phân tán của dòng tiền. Đặc điểm chung của cả hai là đều có hình dáng Lệch phải (Right-skewed) cực kỳ rõ rệt. Bảng thông số thống kê cốt lõi:

Chỉ số thống kê	Tổng chi phí hành trình (Total Cost)	Chi phí / Ngày (Cost per Day)
Trung vị (Median)	2,452 \$	983 \$
Trung bình (Mean)	3,858 \$	1,297 \$
Khoảng phổ biến (25% - 75%)	1,885 \$ – 3,176 \$	706 \$ – 1,504 \$
Ngoại lai (Outliers)	5,118 \$ – 29,994 \$	2,703 \$ – 29,909 \$

Bảng 6. Bảng phân tích chi phí hành trình & chi phí mỗi ngày

Biểu đồ phân phối không có dạng hình chuông đối xứng chuẩn (Bell Curve) mà kéo một chiếc đuôi rất dài về phía bên phải. Hiện tượng lệch phải mạnh mẽ này là minh chứng trực quan cho sự phân hóa tiêu dùng cực kỳ lớn trong tập dữ liệu:


Tầng lớp đại chúng & trung lưu (Phần thân chính): Đại đa số khách hàng nằm trong khoảng phổ biến từ 1,885\$ đến 3,176\$ cho toàn bộ chuyến đi, và chi tiêu mỗi ngày dao động phổ biến từ 706\$ đến 1,504\$. Giá trị trung vị (Median) chỉ ra rằng đúng 50% số lượng chuyến đi trên toàn thế giới có tổng chi tiêu tiết kiệm ở mức dưới 2,452\$ và chi phí mỗi ngày dưới 983\$.

Phân khúc khách hàng siêu cao cấp (VIP Outliers): Chiếc đuôi lệch phải được kéo dài bởi một nhóm nhỏ các điểm ngoại lai (Outliers) có mức chi tiêu cực kỳ đắt đỏ. Tổng chi phí của nhóm này bắt đầu từ 5,118\$ và đạt đỉnh lên đến sát 30,000\$ (29,994\$) cho một chuyến đi, đi kèm chi phí mỗi ngày kỷ lục lên đến 29,909\$ (do có một số chuyến đi công tác cực ngắn ngày của doanh nghiệp sử dụng các chuyến bay hạng nhất và phòng

Tổng thống cao cấp thuộc Dataset 2). Mặc dù nhóm VIP này chiếm tỷ lệ số lượng rất nhỏ trong tổng số 31,780 dòng, nhưng lượng ngân sách họ chi ra lại khổng lồ, tạo thành cực phân hóa lớn trên biểu đồ.

Nếu một doanh nghiệp cung cấp dịch vụ du lịch sử dụng số Trung bình (Mean - 3,858\$) làm chỉ số dự báo doanh thu hoặc định giá gói dịch vụ đại trà, họ sẽ đánh giá quá cao khả năng chi trả của tập khách hàng phổ thông, dẫn đến nguy cơ thất bại khi tung sản phẩm ra thị trường vì giá vượt quá ngân sách của số đông.

Để phản ánh đúng thực tế hành vi của đại đa số khách hàng đại chúng, doanh nghiệp bắt buộc phải sử dụng con số Trung vị (Median - 2,452\$) làm thước đo trung tâm. Về mặt thống kê, con số này giúp loại bỏ hoàn toàn các nhiễu động từ nhóm khách siêu giàu, đưa ra bức tranh tiêu dùng chân thực nhất của thị trường du lịch trung lưu.



Hình 3.8 Biểu đồ Chi phí với Đường Trung bình động (Rolling Means)

Biểu đồ này biểu diễn sự biến động của chi phí trung bình hàng tháng trải dài từ cuối năm 2019 đến giữa năm 2025. Do dữ liệu thu thập theo từng tháng thường biến động cực kỳ mạnh (nay lên, mai xuống) do yếu tố mùa vụ, các sự kiện ngắn hạn và nhiễu ngẫu nhiên, kỹ thuật Đường trung bình động (Rolling Means) đã được áp dụng nhằm "lọc bỏ nhiễu" và làm lộ diện xu hướng thực sự của thị trường du lịch. Dưới đây là bảng đối chiếu chi tiết các đường tín hiệu trên biểu đồ:

Đường tín hiệu	Đặc điểm trên biểu đồ	Ý nghĩa phân tích
Đường màu xanh nhạt (Thực tế - Actual)	Hình zích zắc, dao động cực kỳ mạnh, liên tục tạo ra các đỉnh và đáy nhọn liên tiếp.	Là dữ liệu thực tế thô theo từng tháng. Chứa quá nhiều "nhiều" (noise) do tính mùa vụ ngắn hạn, gây khó khăn cho việc nhận định xu hướng dài hạn của thị trường.
Đường màu Đỏ (Trung bình động 3 tháng)	Mượt mà hơn đường xanh nhạt, cắt gọt bớt các đỉnh/đáy quá sắc nhọn. Nhanh chóng bám sát cú tăng tốc cực hạn trong năm 2023.	Phản ánh xu hướng ngắn hạn và tính mùa vụ theo Quý. Giúp các nhà hoạch định xác định nhanh chóng sự đổi chiều hoặc các điểm uốn của thị trường.
Đường màu Xanh lá (Trung bình động 6 tháng)	Cực kỳ mượt mà, có độ trễ (lag) nhất định so với đường Đỏ và đường Xanh nhạt.	Phản ánh chu kỳ kinh tế dài hạn (Macro Trend) của thị trường. Giúp nhìn thấy bức tranh toàn cảnh một cách khách quan thay vì bị đánh lừa bởi một tháng đột biến đột xuất nào đó.

Bảng 7. Bảng phân tích chi phí với đường trung bình động (Rolling Means)

1. Giai đoạn cuối 2019 - cuối 2022: Bình ổn và Phục hồi sau đại dịch (Đi ngang)

- Đặc điểm xu hướng: Đây là giai đoạn thị trường hoạt động ổn định và phục hồi vững chắc sau những biến động của đại dịch toàn cầu.

- Phân tích số liệu: Dòng tiền chi tiêu trung bình duy trì trạng thái đi ngang đều đặn xung quanh ngưỡng ngân sách từ 3,500\$ đến 4,000\$ cho mỗi chuyến đi trong suốt các năm 2020, 2021 và ba quý đầu năm 2022. Đường Xanh lá (Rolling 6 tháng) đi ngang rất phẳng, thể hiện một thị trường có độ cân bằng cung - cầu cực kỳ tốt, giá cả dịch vụ lữ hành ổn định và hành vi chi tiêu của du khách duy trì ở mức trung lưu bình ổn.

2. Giai đoạn Nửa đầu năm 2023: Tăng nóng và Bùng nổ cực hạn (Tạo đỉnh khổng lồ)

- Đặc điểm xu hướng: Cả hai đường Đỏ và Xanh lá đều dốc ngược lên gần như thẳng đứng, tạo thành một "ngọn núi" khổng lồ trên biểu đồ. Đây là chu kỳ tăng nóng cực hạn của dòng tiền du lịch toàn cầu.

- Phân tích số liệu: Từ mức trung bình 4,500\$ vào tháng 1/2023, chi phí trung bình liên tục bứt phá qua các tháng: đạt 5,773\$ vào tháng 3, bùng nổ lên 8,545\$ vào tháng 6, và chạm mức đỉnh lịch sử không lồ 15,404\$ vào tháng 8/2023. Sự kiện này kéo dài liên tiếp trong nhiều tháng chứ không phải là hiện tượng nhất thời của một tháng đơn lẻ.

- Ý nghĩa kinh tế: Hiện tượng tăng nóng này phản ánh xu hướng "du lịch trả thù" (revenge travel) đạt đến đỉnh điểm sau thời gian dài bị kìm kẹp, kết hợp với lạm phát giá vé máy bay và sự lên ngôi của các dịch vụ nghỉ dưỡng cao cấp (đặc biệt là các chuyến đi dài ngày ghi nhận trong Dataset 2).


3. Giai đoạn Cuối 2023 - năm 2025: Hạ nhiệt, Điều chỉnh và Ổn định bền vững

- Đặc điểm xu hướng: Sau khi chạm đỉnh vào tháng 8/2023, thị trường bước vào pha điều chỉnh mạnh và hạ nhiệt sâu. Đường trung bình động Xanh lá trượt dốc từ từ, phản ánh sự chuyển dịch rõ rệt trong hành vi tiêu dùng của du khách.

Phân tích số liệu: Từ tháng 9/2023, chi phí trung bình đột ngột rơi mạnh và đi vào vùng bình ổn mới thấp hơn, dao động chủ yếu trong khoảng 1,000\$ đến 2,000\$ trong suốt năm 2024 và năm 2025.

- Ý nghĩa kinh tế: Giai đoạn này đánh dấu sự kết thúc hoàn toàn của "chu kỳ tăng nóng" năm 2023. Du khách bắt đầu thắt chặt hầu bao, ưu tiên các chuyến đi ngắn ngày hoặc trung bình để tiết kiệm chi phí trong bối cảnh thắt chặt chi tiêu kinh tế vĩ mô. Thị trường quay trở lại quỹ đạo tiêu dùng cân bằng và mang tính bền vững dài hạn.

3.4.3 Biểu đồ phân phối theo độ tuổi



Hình 3.9 Biểu đồ Cơ cấu Độ tuổi và Giới tính

Biểu đồ này tiết lộ tập khách hàng của hệ thống phân hóa cực kỳ mạnh theo cả độ tuổi lẫn giới tính.

Nhóm Tuổi (Age Group)	Nam giới (Male)	Nữ giới (Female)	Phi nhị giới (Non-binary)	Tổng cộng nhóm tuổi	Tỷ trọng nhóm (%)
Trẻ em (<18 tuổi)	21	14	10	45	0.14%
Thanh niên (18-25 tuổi)	1,074	2,030	78	3,182	10.25%
Người trưởng thành (26-35 tuổi)	2,383	4,190	135	6,708	21.62%
Trung niên (36-50 tuổi)	3,156	7,246	187	10,589	34.13%
Trung cao niên (51-65)	3,517	6,422	186	10,125	32.63%

tuổi)					
Cao niên (>65 tuổi)	126	111	143	380	1.23%
Tổng cộng theo giới tính	10,277	20,013	739	31,029	100.0%

Bảng 8. Bảng phân tích cơ cấu độ tuổi và giới tính

1. Định vị phân khúc khách hàng cốt lõi của thị trường

Số liệu thống kê thực tế cho thấy cơ cấu độ tuổi của hành khách phân bố tập trung cao độ tạo thành hình dáng phân phối gần giống phân phối chuẩn (Normal Distribution) lệch nhẹ:

- Trọng tâm thị trường tiêu dùng: Hai nhóm tuổi chiếm tỷ trọng áp đảo lớn nhất là Trung niên (36-50 tuổi) với 10,589 người (chiếm 34.13%) và Trung cao niên (51-65 tuổi) với 10,125 người (chiếm 32.63%). Kế tiếp là nhóm Người trưởng thành (26-35 tuổi) với 6,708 người (chiếm 21.62%).
- Phân tích hành vi: Tổng cộng ba nhóm tuổi lao động từ 26 đến 65 tuổi chiếm tới ~88.38% toàn bộ tệp dữ liệu. Đây là lực lượng khách hàng cốt lõi có sự độc lập hoàn toàn về mặt tài chính, có tính tích lũy cao và có tần suất di chuyển lớn phục vụ cho cả hai mục đích: đi công tác (business travel) và du lịch nghỉ dưỡng gia đình (vacation).
- Nhóm thiểu số: Nhóm cực hạn như Trẻ em (<18 tuổi) chỉ có 45 người (0.14%) và Cao niên (>65 tuổi) chỉ có 380 người (1.23%) chiếm tỷ lệ không đáng kể, phản ánh thực tế rằng các đối tượng này thường không phải là người trực tiếp ra quyết định đặt chỗ hoặc thanh toán các chi phí hành trình dài ngày độc lập.

2. Sự thống trị của Nữ giới (Female) trong tiêu dùng dịch vụ du lịch

Một phát hiện vô cùng quan trọng về mặt giới tính là sự áp đảo mạnh mẽ của nữ giới trên hầu hết các phân khúc tuổi chính:

- Trong tổng số 31,029 hành khách được ghi nhận đầy đủ nhân khẩu học, nữ giới chiếm tới 20,013 người (khoảng 64.5%), gấp gần 2 lần so với nam giới (10,277 người, khoảng 33.1%).
- Đặc biệt ở nhóm tuổi đông đảo nhất là Trung niên (36-50 tuổi), nữ giới chiếm tới 7,246 người (68.43%), trong khi nam giới chỉ có 3,156 người (29.80%).
- Ý nghĩa thực tiễn: Điều này chứng minh nữ giới đóng vai trò là chủ thể quyết định chi tiêu và là tệp khách hàng mục tiêu lớn nhất của ngành du lịch lữ hành. Nữ giới thường có


xu hướng chủ động lên kế hoạch chuyến đi, đặt chỗ lưu trú, săn vé máy bay và chú trọng đến việc trải nghiệm dịch vụ nhiều hơn.

3. Xu hướng tiến bộ xã hội thông qua sự xuất hiện của nhóm Phi nhị giới (Non-binary)

Tập dữ liệu ghi nhận sự hiện diện nhất quán của nhóm khách hàng Phi nhị giới (Non-binary) phân bố đều đặn ở tất cả các độ tuổi với tổng số lượng 739 người (chiếm 2.38%).

Thú vị là ở nhóm tuổi Cao niên (>65 tuổi), nhóm Non-binary lại chiếm đa số nhẹ với 143 người (37.63%), vượt qua cả nam giới (126 người) và nữ giới (111 người).

Ý nghĩa thực tiễn: Việc thu thập và ghi nhận cụ thể nhóm giới tính phi nhị giới thể hiện tính bao trùm, hiện đại và văn minh của hệ thống khảo sát dữ liệu du lịch đa nguồn thế hệ mới, giúp doanh nghiệp thiết kế các dịch vụ mang tính cá nhân hóa cao và tôn trọng sự đa dạng của khách hàng.



Hình 3.10 Biểu đồ Mức độ chịu chi theo Độ tuổi

Nhóm Tuổi (Age Group)	Số mẫu (n)	Trung bình (Mean)	Trung vị (Median)	Q25 (25%)	Q75 (75%)	Giá trị cực đại (Max)
Trẻ em (<18 tuổi)	58	3,422 \$	1,170 \$	675 \$	2,128 \$	28,849 \$
Thanh niên (18-25 tuổi)	3,271	1,333 \$	975 \$	684 \$	1,497 \$	28,486 \$
Người trưởng	6,842	1,267 \$	991 \$	701 \$	1,512 \$	28,648 \$

thành (26-35 tuổi)						
Trung niên (36-50 tuổi)	10,800	1,269 \$	982 \$	722 \$	1,485 \$	29,909 \$
Trung cao niên (51-65 tuổi)	10,319	1,268 \$	978 \$	706 \$	1,491 \$	29,608 \$
Cao niên (>65 tuổi)	490	2,441 \$	1,086 \$	626 \$	2,191 \$	29,694 \$

Bảng 9. Thống kê mức chi tiêu mỗi ngày (Cost per Day) theo nhóm tuổi du khách

1. Sự đồng nhất đáng ngạc nhiên ở các nhóm tuổi lao động chính (18 - 65 tuổi)

Phát hiện nổi bật nhất từ bảng thống kê là bốn nhóm tuổi lao động trung tâm (Thanh niên, Người trưởng thành, Trung niên, Trung cao niên) — chiếm tổng cộng hơn 31,200 mẫu (98% tổng dữ liệu) — đều có mức chi tiêu mỗi ngày gần như đồng nhất hoàn toàn:

Trung vị chi tiêu mỗi ngày dao động cực kỳ hẹp trong khoảng 975\$ đến 991\$, chênh lệch chỉ khoảng 16\$/ngày giữa nhóm cao nhất và thấp nhất.

Khoảng tứ phân vị (Q25 - Q75) cũng hầu như trùng khớp: từ khoảng 684\$ - 722\$ (cận dưới) đến 1,485\$ - 1,512\$ (cận trên).

→ Ý nghĩa: Điều này chứng minh rằng tuổi tác không phải là yếu tố quyết định trực tiếp đến mức chi tiêu mỗi ngày đối với nhóm khách hàng trong độ tuổi lao động. Thay vào đó, các yếu tố như điểm đến, loại hình lưu trú, thời điểm mùa vụ và mục đích chuyến đi mới thực sự chi phối ngân sách hàng ngày của du khách.

2. Hiện tượng "đuôi dài" (Long Tail) và Outliers cực đại ở hai nhóm cực hạn

Trên biểu đồ Boxplot, hai nhóm tuổi ở hai đầu phổ tuổi cho thấy sự phân tán dữ liệu rộng hơn đáng kể:

Nhóm Trẻ em (<18 tuổi): Mặc dù chỉ có 58 mẫu (chiếm 0.18%), nhưng giá trị trung bình lại đạt 3,422\$/ngày — cao gấp gần 3 lần so với các nhóm tuổi lao động. Nguyên nhân chính là do nhóm này thường đi cùng gia đình có thu nhập cao, hưởng thụ các dịch vụ cao cấp mà cha mẹ chi trả. Trung vị thấp hơn nhiều (1,170\$) cho thấy số liệu bị kéo lệch bởi một số ít chuyến đi siêu sang, trong khi phần lớn các chuyến đi gia đình có con nhỏ vẫn nằm ở mức chi tiêu hợp lý.

Nhóm Cao niên (>65 tuổi): Tương tự với 490 mẫu, giá trị trung bình là 2,441\$/ngày — gấp gần 2.5 lần nhóm lao động. Nhóm Cao niên thể hiện xu hướng phân hóa mạnh mẽ nhất: một bộ phận du khách cao tuổi ưu tiên các dịch vụ chăm sóc sức khỏe, nghỉ dưỡng hạng sang và tour du thuyền cao cấp (kéo trung bình lên cao), trong khi một bộ phận khác đi du lịch tiết kiệm với ngân sách rất khiêm tốn (Q25 chỉ có 626\$, thấp nhất trong tất cả các nhóm).

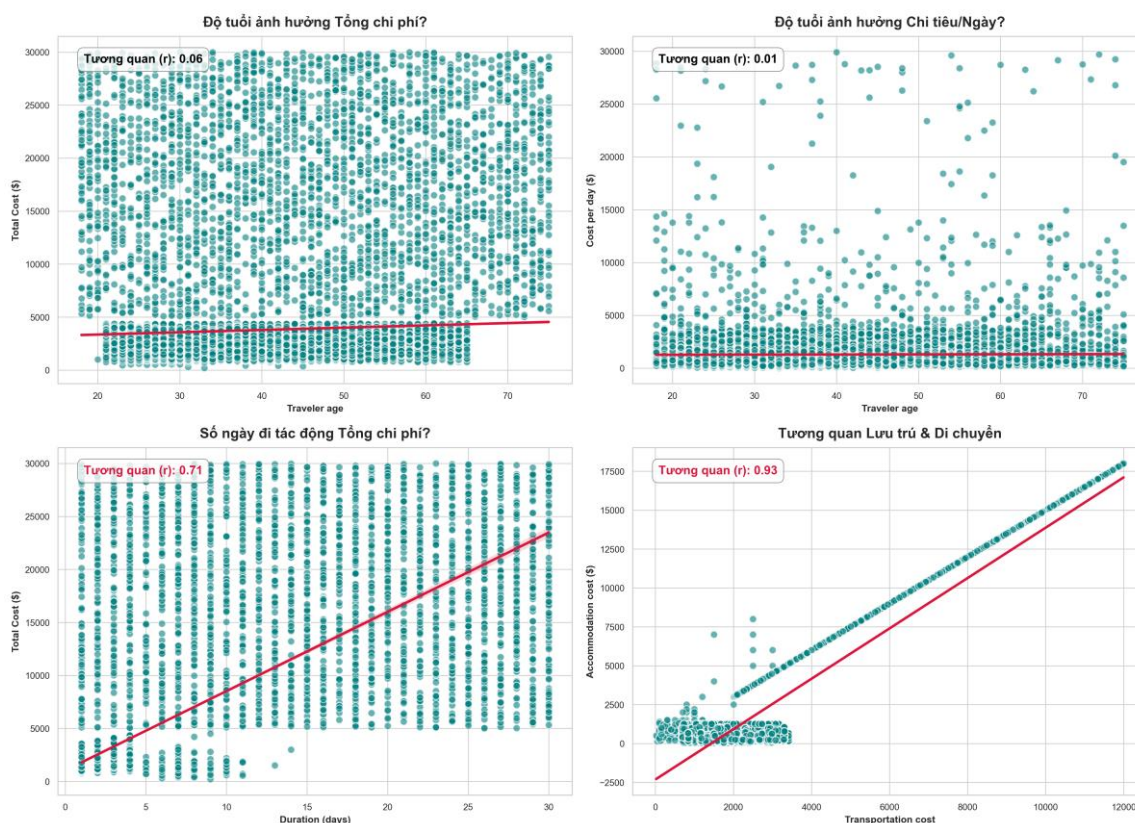
3. Vai trò của Stripplot trong việc "phơi bày" mật độ phân bố thực tế

Các điểm hạt nhiều (Stripplot) phủ lên biểu đồ hộp giúp trực quan hóa mật độ phân bố thực tế mà Boxplot không thể hiện được. Ở bốn nhóm tuổi lao động, mật độ điểm tập trung dày đặc ở vùng thấp (dưới 2,000\$/ngày), tạo thành một "dải sương mù đen" dày ở phần dưới biểu đồ. Trong khi đó, phía trên vùng 5,000\$/ngày chỉ có lác đác vài điểm ngoại lai phân tán thưa thớt.

Riêng ở nhóm Trẻ em và Cao niên, các điểm Stripplot phân tán rộng và dàn trải hơn đáng kể, phản ánh tính không đồng nhất cao trong hành vi chi tiêu và khẳng định kết quả phân tích bằng số liệu ở trên.

3.4.4 Biểu đồ tương quan

Ma Trận Phân Tán Đa Chiều (Kèm Đường Xu Hướng Tuyến Tính)



Hình 3.11 Biểu đồ Ma Trận Tương Quan Đa Chiều

Bốn biểu đồ này giải đáp các "định kiến" thông thường của chúng ta về hành vi du lịch bằng các con số toán học khách quan:

A. Định kiến 1: “Càng lớn tuổi, đi du lịch càng tốn kém vì yêu cầu dịch vụ cao”

- Biểu đồ: Top-Left (Traveler age vs Total Cost) và Top-Right (Traveler age vs Cost per day).

- Thực tế: Cả hai biểu đồ đều gần như phẳng, không cho thấy xu hướng tăng/giảm rõ ràng theo độ tuổi. Hệ số tương quan lần lượt chỉ ở mức rất thấp: $r = 0.06$ và $r = 0.01$.

→ Kết luận: Độ tuổi gần như không phải biến quyết định mức chi tiêu. Người trẻ hay người lớn tuổi đều có thể chi tiêu cao hoặc thấp tùy theo phong cách du lịch và mức độ xa xỉ của dịch vụ.

B. Định kiến 2: “Đi du lịch càng nhiều ngày thì càng tốn nhiều tiền”

- Biểu đồ: Bottom-Left (Duration (days) vs Total Cost).

- Thực tế: Đây là biểu đồ thể hiện xu hướng tăng khá rõ rệt. Đường hồi quy đi lên tương đối mạnh, với hệ số tương quan $r = 0.71$.


→ Kết luận: Định kiến này phần nào là đúng. Càng đi lâu, tổng chi phí nhìn chung càng tăng, nhưng không phải theo kiểu tuyến tính tuyệt đối. Mức chi tiêu thực tế vẫn còn phụ thuộc vào phân khúc dịch vụ, nên có những chuyến đi ngắn nhưng rất đắt, và cũng có những chuyến đi dài nhưng tiết kiệm hơn.

C. Định kiến 3: “Người ta thường dồn tiền cho vé máy bay, bù lại sẽ ở khách sạn rẻ, hoặc ngược lại”

- Biểu đồ: Bottom-Right (Transportation cost vs Accommodation cost).

- Thực tế: Đây là mối tương quan mạnh nhất trong bốn biểu đồ, với đường xu hướng tăng rất rõ và các điểm dữ liệu bám sát đường hồi quy. Hệ số tương quan đạt $r = 0.93$.

→ Kết luận: Hai khoản chi này gần như đi cùng nhau. Khách hàng chi mạnh cho đi chuyến thì thường cũng chi mạnh cho lưu trú, cho thấy một “phong cách du lịch” thống nhất hơn là kiểu bù trừ giữa hai loại chi phí.



Hình 3.12 Bản đồ Nhiệt (Heatmap) - Ma trận Tương quan các đặc trưng số

Nhìn vào ma trận tương quan, điều dễ thấy nhất là dữ liệu không “rời rạc” hoàn toàn mà tụ lại thành vài nhóm khá rõ. Nổi bật nhất là nhóm các biến liên quan đến chi phí, vì chúng có xu hướng đi cùng nhau rất mạnh. Trong đó, chi phí lưu trú gần như là yếu tố trung tâm, bởi nó gắn chặt với tổng chi phí chuyến đi ở mức rất cao. Chi phí di chuyển cũng có liên hệ mạnh với tổng chi phí, nhưng vẫn đứng sau lưu trú một chút. Điều này cho thấy tổng tiền cho một chuyến đi không chỉ phụ thuộc vào một khoản riêng lẻ, mà thường phản ánh cả một “phong cách chi tiêu” thống nhất của khách du lịch.

Ngược lại, các biến như độ tuổi hay những yếu tố thời gian lại không thể hiện ảnh hưởng rõ rệt. Chúng chỉ cho thấy mức tương quan rất thấp, nghĩa là nếu chỉ nhìn vào chúng thì khó dự đoán được mức chi tiêu của chuyến đi. Một điểm đáng chú ý nữa là các biến chi phí theo ngày cũng có quan hệ khá chặt với các biến chi phí chính, nên nếu đưa tất cả vào cùng một mô hình tuyến tính thì rất dễ gặp tình trạng trùng lặp thông tin. Vì


vậy, biểu đồ này không chỉ giúp thấy biến nào liên quan mạnh, mà còn nhắc rằng cần cẩn thận khi chọn biến đầu vào cho mô hình.

Cặp biến số	Hệ số tương quan (r)	Mức độ	Ý nghĩa thực tiễn
Total Cost & Accommodation Cost	0.98	Rất mạnh (+)	Chi phí lưu trú gần như quyết định quy mô tổng chi phí chuyến đi. Đây là biến giải thích mạnh nhất.
Total Cost & Cost per day	0.98	Rất mạnh (+)	Chuyến đi càng đắt thì mức chi tiêu trung bình mỗi ngày càng cao, phản ánh phong cách du lịch “chịu chi”.
Accommodation Cost & Accommodation cost per day	0.98	Rất mạnh (+)	Lưu trú theo ngày và tổng chi phí lưu trú gần như tuyến tính với nhau, cho thấy đây là một cụm biến trùng thông tin.
Total Cost & Transportation Cost	0.89	Mạnh (+)	Chi phí di chuyển đóng góp đáng kể vào tổng chi phí, nhưng vẫn thấp hơn lưu trú.
Transportation Cost & Accommodation Cost	0.93	Rất mạnh (+)	Khách hàng chi mạnh cho vé máy bay thì thường cũng chi mạnh cho nơi ở. Hai khoản này tăng giảm đồng pha.
Duration (days) & Total Cost	-0.09	Rất yếu (-)	Đi dài ngày không làm tổng chi phí tăng mạnh theo tuyến tính.
Duration (days) & Cost per	-0.25	Yếu đến vừa (-)	Đi càng lâu, chi phí

day			trung bình mỗi ngày có xu hướng giảm.
Duration (days) & Accommodation cost per day	-0.26	Yếu đến vừa (-)	Lưu trú dài ngày thường giúp tối ưu giá theo ngày, như thuê dài hạn hoặc giảm giá theo gói.
Traveler age & các biến chi phí	0.01–0.06	Rất yếu (+)	Độ tuổi gần như không có vai trò quyết định trong việc dự báo chi phí.
Travel Month / Travel Year / Travel Quarter & chi phí	-0.03 đến 0.14	Yếu	Các biến thời gian chỉ phản ánh phần nào tính mùa vụ, không phải yếu tố chi phối chính.

Bảng 10. Bảng phân tích ma trận tương quan các đặc trưng số

3.4.5 Một vài biểu đồ khác



Hình 3.13 Biểu đồ Mức độ chịu chi theo Độ tuổi


Biểu đồ này so sánh sự khác biệt giữa thị hiếu đám đông (bên trái) và độ xa xỉ của các quốc gia/vùng lãnh thổ (bên phải).

Hạng mục	Top 3 dẫn đầu	Nhận xét phân tích
Phổ biến nhất (Lượng khách)	1. Florianopolis (SC) - 5752 2. Aracaju (SE) - 4483 3. Campo Grande (MS) - 4252	Các điểm đến được chọn nhiều nhất đều có lượng khách rất cao và chênh lệch tương đối rõ so với nhóm phía dưới.
Đắt đỏ nhất (Chi phí / Ngày)	1. Greece - 2373 2. Salvador (BH) - 1479 3. New Zealand - 1357	Greece là điểm đến đắt nhất vượt trội, cao hơn khá xa so với hai vị trí còn lại. Đây là nhóm chi phí/ngày rất cao, thiên về trải nghiệm cao cấp hoặc đặc thù.

Bảng 11. Bảng phân tích mức độ chịu chi theo độ tuổi

Biểu đồ cho thấy một sự khác biệt khá rõ giữa nơi được chọn nhiều và nơi đắt đỏ nhất. Ở nhóm phổ biến, các điểm đến dẫn đầu chủ yếu là những thành phố quen thuộc trong nước như Florianopolis, Aracaju, Campo Grande, Brasilia và Recife. Điều này cho thấy khách hàng thường ưu tiên các điểm đến dễ tiếp cận, có sức hút ổn định và phù hợp với nhu cầu du lịch đại chúng hơn là những nơi quá đặc biệt hay quá xa xỉ.

Ngược lại, nhóm đắt đỏ lại nghiêng về các điểm đến có chi phí trung bình mỗi ngày rất cao, nổi bật nhất là Greece và New Zealand. Đây là dấu hiệu cho thấy mức độ đắt đỏ không đi cùng với độ phổ biến. Một số địa điểm như Greece vừa xuất hiện trong nhóm phổ biến vừa đứng đầu nhóm đắt đỏ, nghĩa là điểm đến hấp dẫn không nhất thiết là điểm đến rẻ. Nói cách khác, có những nơi được nhiều người chọn vì giá trị trải nghiệm, nhưng vẫn thuộc phân khúc chi tiêu cao.



Hình 3.14 Biểu đồ Mức độ chịu chi theo năm tháng và mùa vụ

Hệ thống biểu đồ này cho thấy tính mùa vụ của du lịch không quá lệch mạnh, nhưng vẫn có những dao động khá rõ giữa các giai đoạn trong năm.

A. Về tỷ trọng theo mùa

- Bốn mùa có tỷ trọng khá cân bằng, không mùa nào chiếm ưu thế tuyệt đối.

- Mùa Đông chiếm tỷ trọng cao nhất, khoảng 26.6%.
- Mùa Thu đứng ngay sau với khoảng 25.9%.
- Mùa Xuân cũng ở mức tương đương, khoảng 25.2%.
- Mùa Hè là mùa thấp nhất trong bốn mùa, chỉ khoảng 22.3%.

→ Điều này cho thấy nhu cầu du lịch không tập trung dồn mạnh vào riêng mùa hè như nhiều người thường nghĩ, mà phân bố khá đều quanh năm.

B. Về biến động số lượng và chi phí theo tháng

Ở biểu đồ theo tháng, số lượng chuyến đi dao động trong một biên độ tương đối hẹp, chủ yếu quanh mức 2.300 đến hơn 3.000 chuyến/tháng.

Nhóm tháng có lượng khách cao hơn nằm ở tháng 1, tháng 10, tháng 11 và tháng 12, trong đó tháng 10 là một trong những tháng nổi bật nhất về số chuyến đi.

Ngược lại, tháng 7, tháng 8 và tháng 9 là giai đoạn lượng khách giảm xuống thấp hơn so với các tháng còn lại.

Về chi phí trung bình, đường đồ biến động rõ hơn số lượng khách. Chi phí tăng mạnh ở tháng 5, tháng 6 và tháng 8, tức là có những giai đoạn giá dịch vụ cao dù lượng khách không phải lúc nào cũng cao nhất.

Tháng 11 là điểm thấp nhất về chi phí trung bình, trong khi tháng 8 và tháng 6 lại nằm trong nhóm cao nhất.

Điều này cho thấy chi phí du lịch không chỉ phụ thuộc vào lượng khách mà còn phụ thuộc vào loại hình chuyến đi, thời điểm đặt dịch vụ và mức độ cao cấp của hành trình.

→ Kết luận:

- Du lịch trong dữ liệu này có tính mùa vụ, nhưng không quá cực đoan.
- Nhu cầu giữa các mùa tương đối cân bằng, còn biến động theo tháng lại thể hiện rõ hơn ở mặt chi phí.
- Nói cách khác, có những tháng khách không quá đông nhưng chi phí vẫn cao, cho thấy thị trường du lịch chịu ảnh hưởng đồng thời bởi mùa, loại hình dịch vụ và phân khúc khách hàng.

3.5 Phân tích dữ liệu /Xây dựng mô hình

3.5.1 Chuẩn bị dữ liệu cho mô hình

- Mục tiêu dự đoán (Target): Dự báo Chi phí Lưu trú (Accommodation cost) của một chuyến du lịch dựa trên các thông tin nhân khẩu học và hành trình. Features sử dụng (6 biến đầu vào):

STT	Feature	Loại dữ liệu	Mô tả
1	Traveler age	Số (Numeric)	Độ tuổi của khách du lịch
2	Duration (days)	Số (Numeric)	Tổng số ngày kéo dài chuyến đi
3	Destination	Chuỗi (Categorical)	Quốc gia/Thành phố đích đến
4	Traveler gender	Chuỗi (Categorical)	Giới tính khách hàng
5	Accommodation type	Chuỗi (Categorical)	Hạng mục lưu trú (Khách sạn, Resort, Hostel...)
6	Transportation type	Chuỗi (Categorical)	Phương tiện di chuyển (Máy bay, Tàu hỏa, Ô tô...)

Bảng 12. Các features dành cho mô hình

- Kỹ thuật Tiền xử lý (Preprocessing):

Sử dụng OneHotEncoder để chuyển đổi 4 biến Chuỗi (Categorical) sang dạng các cột nhị phân (0-1) để thuật toán có thể đọc được dữ liệu.

- Chia dữ liệu (Train - Test Split):

+ Tập train: 80% dữ liệu - Dùng để huấn luyện cho mô hình học các quy luật.

+ Tập test: 20% dữ liệu - Dùng để làm bài kiểm tra ẩn, đánh giá độ chính xác thực tế của mô hình.

3.5.2 Mô hình dự báo: *Random Forest Regressor (Tuned)*

Cách hoạt động: Xây dựng 300 cây quyết định (Decision Trees) khác nhau. Mỗi cây học độc lập trên một mẫu dữ liệu con ngẫu nhiên. Kết quả dự báo chi phí cuối cùng là mức giá trung bình được tổng hợp từ 300 cây này, giúp triệt tiêu sự thiên lệch và tránh học vẹt (Overfitting).

Feature Importance (Độ quan trọng của các biến): Dựa trên thuật toán trích xuất của mô hình, mức độ tác động của các yếu tố đến Chi phí Lưu trú được xếp hạng như sau:

STT	Feature (Đặc trưng)	Độ quan trọng	Tỷ lệ ảnh hưởng
1	Điểm đến (Destination)	0.847	84.7%
2	Độ tuổi (Traveler age)	0.044	4.4%
3	Số ngày đi (Duration (days))	0.044	4.4%
4	Phương tiện di chuyển (Transportation type)	0.026	2.6%
5	Hạng mục lưu trú (Accommodation type)	0.022	2.2%
6	Giới tính (Traveler gender)	0.018	1.8%

Bảng 13. Bảng mô tả độ quan trọng và tỷ lệ ảnh hưởng của các features

→ Kết luận: Điểm đến (Destination) là yếu tố thống trị hoàn toàn, chiếm tới hơn 84.7% mức độ ảnh hưởng đến biến động chi phí lưu trú của chuyến đi. Các yếu tố còn lại như Độ tuổi, Số ngày đi, Phương tiện di chuyển, Loại hình lưu trú và Giới tính có tác động rất nhỏ (chỉ từ 1.8% đến 4.4%). Điều này cho thấy vị trí địa lý của điểm đến quyết định phần lớn mức giá lưu trú thực tế.

3.6 Kết quả thực nghiệm và đánh giá

3.6.1 Các chỉ số đánh giá (Metrics)

Chỉ số	Công thức thuật toán	Ý nghĩa thực tiễn
MAE	<code>mean_absolute_error(y_test, y_pred)</code>	$y_{\text{actual}} - y_{\text{pred}}$ Đo lường mức độ sai lệch trung bình (trị tuyệt đối) giữa giá trị dự báo và giá trị thực tế. Cho biết trung bình mô hình dự báo lệch khoảng bao nhiêu USD so với hóa đơn thực tế.
RMSE	<code>np.sqrt(mean_squared_error(y_test, y_pred))</code>	Căn bậc 2 sai số bình phương TB: Trừng phạt rất nặng các khoản dự báo bị lệch quá xa (Outliers). Phản ánh rủi ro dự báo lệch chuẩn.
R ²	<code>r2_score(y_test, y_pred)</code>	Hệ số xác định (R-Squared): Đo lường tỷ lệ % sự biến thiên của dữ liệu mà mô hình có thể giải thích được. (Mức lý tưởng: Gần 1.0)

Bảng 14. Bảng mô tả các chỉ số đánh giá

3.6.2 Kết quả đạt được của mô hình

Nhằm tìm kiếm giải pháp tối ưu nhất cho bài toán dự báo, chúng tôi tiến hành thử nghiệm và so sánh chéo hiệu suất trên tập kiểm tra (Test Set chiếm 20% dữ liệu) của nhiều mô hình học máy khác nhau bao gồm: Hồi quy tuyến tính (Linear Regression), Rừng ngẫu nhiên (Random Forest), Tăng cường gradient (Gradient Boosting) và XGBoost.

Mô hình thử nghiệm	CV MAE (Trung bình)	MAE (\$)	RMSE (\$)	R ² Score
Hồi quy tuyến tính (Linear Regression)	546.87	543.07	1368.47	0.8205
Rừng ngẫu nhiên (Random Forest - Tuned)	373.58	361.02	1371.82	0.8196

Tăng cường gradient (Gradient Boosting)	397.22	392.92	1350.09	0.8253
XGBoost	402.62	378.93	1449.76	0.7985

Bảng 15. So sánh hiệu suất giữa các mô hình thử nghiệm trên tập Test

→ Nhận xét: Mặc dù Gradient Boosting đạt chỉ số R^2 cao nhất (82.53%), mô hình Random Forest (Tuned) được lựa chọn làm mô hình tối ưu cuối cùng cho hệ thống do đạt sai số trung bình kiểm định chéo (CV MAE = 373.58) thấp nhất và sai số thực tế trên tập kiểm tra (MAE = 361.02) nhỏ nhất, đảm bảo tính ổn định và khả năng tổng quát hóa cao.

- Dưới đây là điểm số đánh giá chi tiết của mô hình Random Forest (Tuned) được lựa chọn:

Metric (Chỉ số)	Kết quả mô hình Random Forest (Tuned)	Đánh giá / Chẩn đoán
MAE	361.02 (\$)	Trung bình mỗi chuyến đi, mô hình dự báo lệch khoảng 361 USD so với hóa đơn lưu trú thực tế.
RMSE	1371.82 (\$)	Mức sai số bị đội lên đáng kể (1371.82 USD) do trong tập Test có chứa những chuyến đi ngoại lai cực kỳ đắt đỏ (Outliers).
R^2 Score	0.8196	Khớp rất tốt (Good Fit): Hệ số R^2 đạt 81.96%, chứng tỏ mô hình dự báo hiệu quả và giải thích được phần lớn sự biến động của chi phí lưu trú.

Bảng 16. Bảng kết quả đạt được của mô hình

Kết quả R^2 đạt mức cao ấn tượng (81.96%) xuất phát từ việc cải thiện quy mô dữ liệu đáng kể: Kích thước tập dữ liệu của chúng ta hiện nay đã đạt tới 31.780 dòng. Rừng ngẫu nhiên (Random Forest) là thuật toán cực kỳ "khát" dữ liệu, việc mở rộng quy mô mẫu giúp mô hình học được các quy luật tổng quát hiệu quả mà không bị học vẹt (Overfitting) hay dự báo sai lệch quá mức trên các tập dữ liệu thực tế.

Để khắc phục các điểm hạn chế và tối ưu hiệu suất mô hình hơn nữa trong tương lai, một số giải pháp quan trọng có thể áp dụng bao gồm:

1. Thu thập thêm các đặc trưng bổ sung như: mùa vụ chi tiết, thời gian đặt phòng trước (booking lead time), phân khúc dịch vụ (luxury/budget) của hãng hàng không và khách sạn.
2. Xử lý chuyên sâu hoặc loại bỏ bớt các chuyển đi quá xa xỉ (Outliers) khỏi tập huấn luyện để giảm thiểu chỉ số RMSE (hiện tại RMSE vẫn còn khá cao ở mức 1371.82 USD do bị ảnh hưởng mạnh bởi các trị ngoại lai này).
3. Thử nghiệm kết hợp các kỹ thuật Ensemble nâng cao (như Stacking, Voting) hoặc kiến trúc mạng Neural để tối đa hóa độ chính xác dự báo.

CHƯƠNG IV: KẾT LUẬN

4.1 Kết quả đạt được

Dự án đã hoàn thành trọn vẹn vòng đời của một dự án Khoa học Dữ liệu (Data Science) và Học máy chuyên sâu, đạt được các kết quả nổi bật sau:

- Xây dựng Pipeline Dữ liệu Tự động & Nhất quán: Thiết lập thành công luồng xử lý dữ liệu tự động từ khâu gộp (merge) nhiều nguồn dữ liệu thô, làm sạch các giá trị khuyết thiếu (Missing Values), chuẩn hóa dữ liệu, đến kỹ nghệ đặc trưng (Feature Engineering). Pipeline đã trích xuất hiệu quả các thuộc tính kinh doanh quan trọng như Chi phí mỗi ngày (Cost per day), Nhóm độ dài chuyến đi (Duration Group), Phân rã thời gian du lịch theo Tháng/Mùa vụ.

- Khám phá Insight Đột phá bằng EDA Chuyên sâu: Tạo dựng hệ thống biểu đồ và dashboard trực quan hóa chất lượng cao (300 DPI), bóc tách thành công các quy luật hành vi tiêu dùng và đặc trưng nhân khẩu học của du khách trên tập dữ liệu thực tế lớn:

- + Bức tranh phân phối chi phí: Chỉ ra sự phân cực lớn trong chi tiêu du lịch và sự ảnh hưởng mang tính quyết định của vị trí địa lý (Điểm đến) tới biến động chi phí lưu trú.

- + Tính mùa vụ rõ rệt: Xác định các tháng cao điểm du lịch (đặc biệt là mùa hè) mang lại doanh thu vượt trội, đối nghịch với các thời kỳ thấp điểm (Tháng 4 và Tháng 11).

- + Chân dung khách hàng mục tiêu: Định vị rõ nét phân khúc khách hàng tiềm năng dựa trên sự kết hợp giữa độ tuổi, giới tính và hành vi chi tiêu thực tế.

- Xây dựng và Tối ưu hóa Hệ thống Học máy Đa mô hình (Ensemble Comparison):

- + Triển khai thành công bộ khung thử nghiệm và so sánh chéo hiệu suất giữa 4 mô hình: Hồi quy tuyến tính (Linear Regression), Rừng ngẫu nhiên (Random Forest), Tăng cường gradient (Gradient Boosting) và XGBoost.

- + Áp dụng kỹ thuật kiểm định chéo 5-fold (5-Fold Cross-Validation) trên tập huấn luyện để lựa chọn mô hình tối ưu một cách khách quan nhất.

- + Tiến hành tinh chỉnh siêu tham số (Hyperparameter Tuning) thành công cho mô hình Random Forest thông qua vòng lặp tối ưu hóa, cấu hình mô hình đạt hiệu năng ấn tượng với hệ số xác định R^2 đạt tới 81.96% và sai số tuyệt đối trung bình MAE giảm xuống còn 361.02 USD trên tập kiểm tra ẩn.

4.2 Hạn chế của dự án

Mặc dù hệ thống Pipeline dữ liệu và mô hình học máy đã được cải tiến vượt bậc và đạt độ chính xác cao, dự án vẫn còn một số điểm hạn chế cần cải thiện:

Ảnh hưởng từ các giá trị ngoại lai (Outliers): Mặc dù sai số trung bình (MAE) đã được tối ưu rất tốt, chỉ số RMSE của mô hình vẫn ở mức tương đối cao (1371.82 USD). Điều này phản ánh sự tồn tại của các chuyến đi xa xỉ (VIP) có mức chi tiêu đột biến cực lớn trong tập dữ liệu, làm lệch các dự báo trung bình và gây khó khăn cho mô hình khi cố gắng khớp đồng thời cả phân khúc phổ thông và siêu VIP.

Hạn chế về các Đặc trưng chuyên sâu (Feature Limitations): Các thuộc tính đầu vào hiện tại chủ yếu xoay quanh thông tin hành trình cơ bản và nhân khẩu học. Mô hình vẫn thiếu vắng các biến số mang tính quyết định trực tiếp tới giá phòng lưu trú thực tế, ví dụ: Phân khúc/Hạng sao nơi lưu trú (khách sạn 3 sao, 5 sao hay homestay bình dân), Thời gian đặt phòng trước (Booking lead time), mục đích chuyến đi (du lịch tự túc, nghỉ dưỡng gia đình, hay công tác), và mức độ tiện nghi đi kèm.

Độ phức tạp tính toán tăng theo quy mô: Khi kích thước dữ liệu được nâng lên 31.780 dòng, quy trình so sánh đa mô hình kết hợp tìm kiếm lưới (GridSearchCV) đòi hỏi nhiều tài nguyên phần cứng và thời gian huấn luyện lâu hơn so với trước đây.

4.3 Hướng phát triển trong tương lai

Để tiếp tục nâng cao hiệu suất dự báo và tính thực tiễn của hệ thống, dự án đề xuất các định hướng nâng cấp sau:

- Tách biệt Mô hình theo phân khúc khách hàng:

Áp dụng các thuật toán phân cụm (như K-Means hoặc Gaussian Mixture Models) để phân chia dữ liệu thành các phân khúc chi tiêu rõ rệt (ví dụ: du lịch tiết kiệm, phổ thông, và hạng sang/VIP).

Huấn luyện các mô hình dự báo chuyên biệt cho từng phân khúc nhằm triệt tiêu ảnh hưởng của các trị ngoại lai lớn, giúp tối ưu hóa chỉ số RMSE.

- Làm giàu kho dữ liệu và đặc trưng (Feature Enrichment):

Tích hợp thêm dữ liệu từ các nền tảng OTA thực tế (như Booking.com, Agoda, TripAdvisor) để bổ sung các thuộc tính quan trọng như: đánh giá của khách hàng (Rating), hạng sao khách sạn, khoảng cách tới trung tâm, các tiện ích đi kèm (bữa sáng, hồ bơi).

Thu thập thêm các biến ngoại cảnh như dữ liệu thời tiết thực tế, tỷ giá hối đoái, hoặc các sự kiện lễ hội lớn tại điểm đến theo từng mốc thời gian.

- Áp dụng các mô hình học máy và học sâu nâng cao:

Thử nghiệm các thuật toán Tree-based thế hệ mới như LightGBM, CatBoost (vốn xử lý biến phân loại cực tốt) kết hợp với các kỹ thuật Ensemble nâng cao (Stacking, Voting Regressor).

Nghiên cứu xây dựng kiến trúc Mạng Neural nhân tạo (Deep Learning) để khai thác các mối quan hệ phi tuyến phức tạp trong tập dữ liệu quy mô lớn (31.780 dòng).

TÀI LIỆU THAM KHẢO

1. McKinney, W. (2022). Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter (3rd Edition). O'Reilly Media. (Tài liệu nền tảng về xử lý dữ liệu và Feature Engineering bằng thư viện Pandas).
2. Géron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems (3rd Edition). O'Reilly Media. (Tài liệu tham khảo chính cho phần xây dựng, tinh chỉnh và đánh giá mô hình Random Forest Regressor).
3. VanderPlas, J. (2016). Python Data Science Handbook: Essential Tools for Working with Data. O'Reilly Media. (Tham khảo chuyên sâu về các kỹ thuật biểu diễn dữ liệu Matplotlib và Seaborn).
4. Provost, F., & Fawcett, T. (2013). Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking. O'Reilly Media. (Tài liệu tham khảo về tư duy phân tích, chuyển đổi dữ liệu thành các Insight kinh doanh).
5. Scikit-learn Developers. (2024). Scikit-learn: Machine Learning in Python. Truy cập từ: <https://scikit-learn.org/stable/> (Tài liệu tra cứu công thức hàm Pipeline, OneHotEncoder và thuật toán RandomForest).
6. Pandas Development Team. (2024). Pandas Documentation. Truy cập từ: <https://pandas.pydata.org/docs/>
7. Waskom, M., et al. (2024). Seaborn: Statistical Data Visualization. Truy cập từ: <https://seaborn.pydata.org/> (Tài liệu tham khảo về các hệ màu chuẩn báo cáo và thông số biểu đồ Heatmap, Scatterplot, Boxplot).
8. Kaggle Community. Travel & Tourism Dataset Repository. Truy cập từ: <https://www.kaggle.com/> (Nền tảng tham khảo các bộ dữ liệu du lịch tương tự để lấy ý tưởng phân tích).
9. Link github: <https://github.com/VVanTien/chuyende3>